Guatemala, 26 de febrero de 2026

CURSO: ESTADÍSTICA PARA DATA SCIENCE
CATEDRÁTICO: MSC. LUIS PEDRO FLORES
DOCUMENTO: LABORATORIO NO.5

NOMBRE: DIEGO JAVIER MORALES MONZÓN **CARNÉ:** 1132119
NOMBRE: ESTUARDO JOSÉ VILLEDA NAVARRO **CARNÉ:** 1003519
NOMBRE: JORGE WALDEMAR GARCÍA BALDIZÓN **CARNÉ:** 1220019
NOMBRE: JOSÉ DANIEL DE LEÓN CHANG **CARNÉ:** 1170419

INSTRUCCIONES: El ejercicio presenta una serie de datos de la empresa de Retail, que tiene como objetivo entender los patrones de tendencia central para obtener insights de productos, categorías, regiones otros datos, en donde más venta y resultados se tienen.

PREGUNTAS

1) Identificación de valores faltantes: Realiza un análisis para identificar las variables que contienen valores faltantes.

```
#VALORES FALTANTES
missing_values <- colSums(is.na(df))
missing_values

66:1   (Top Level) ÷
Console   Terminal ×   Background Jobs ×
R 4.5.2 · C:/Users/jdele/OneDrive/Escritorio/Maestria/Estadistica para Data Science/Lab 5/
                                        Mean   :44.19
                                        3rd Qu.:52.00
                                        Max.   :89.00
imputar_moda(Home.Owner)
Length:1000
Class :character
Mode  :character


Q1 <- quantile(df_limpio$Income, 0.25)
Q3 <- quantile(df_limpio$Income, 0.75)

IQR <- Q3 - Q1
limite_superior <- Q3+ IQR*1.5
df_limpio[df_limpio$Income > limite_superior,] <- limite_superior
boxplot(df_limpio$Income)
df_limpio[df_limpio$Income > limite_superior,] <- limite_superior
boxplot(df_limpio$Income)
missing_values <- colSums(is.na(df))
missing_values
                    ID          Marital.Status                  Gender                  Income                Children
                     0                       0                       0                       6                       8
             Education              Occupation             Home.Owner                    Cars        Commute.Distance
                     0                       0                       4                       9                       0
                Region                     Age         Purchased.Bike imputar_moda(Home.Owner)
                     0                       8                       0                       0
```

Pregunta: ¿Qué variables tienen datos faltantes y cuántos valores faltan por variable? ¿Qué patrones observas en la distribución de los valores faltantes?

El análisis de valores faltantes muestra que las variables con datos incompletos son:

- Income con 6 valores faltantes
- Children con 8 valores faltantes
- Home.Owner con 4 valores faltantes
- Cars con 9 valores faltantes
- Age con 8 valores faltantes

2. Imputación de valores faltantes en las variables numéricas: Imputa los valores faltantes de las variables numéricas utilizando la media, mediana y otros métodos de imputación (como la regresión).

```
> df_regresion[,c( Income ,  Age ,  Cars ,  Children )]
> summary(df_media$Income)
 Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
10000   30000   60000   56268   70000  170000 
> summary(df_mediana$Income)
 Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
10000   30000   60000   56290   70000  170000 
> summary(df_regresion$Income)
 Min. 1st Qu.  Median    Mean 3rd Qu.    Max. 
10000   30000   60000   56150   70000  170000 
> libreria p
```

Pregunta: ¿Qué diferencias observas entre los resultados obtenidos al imputar los valores faltantes con la media, mediana o métodos avanzados como la regresión?

Al comparar los resultados en la variable Income, se observó lo siguiente:

- Con media, el promedio fue 56,268.
- Con mediana, el promedio fue 56,290.
- Con regresión (MICE), el promedio fue 56,150.

Las diferencias entre los métodos son pequeñas, lo que indica que el porcentaje de valores faltantes no era alto y no afecta significativamente la distribución general.

Sin embargo, el método de regresión (MICE) es más robusto porque considera la relación entre variables y mantiene mejor la estructura del conjunto de datos, mientras que la media y la mediana simplemente reemplazan los valores faltantes por un único valor fijo.

3. Suavización de datos atípicos en los ingresos (Income): Realiza un análisis visual utilizando un gráfico de caja y bigotes (boxplot) para identificar valores atípicos en la variable Income.

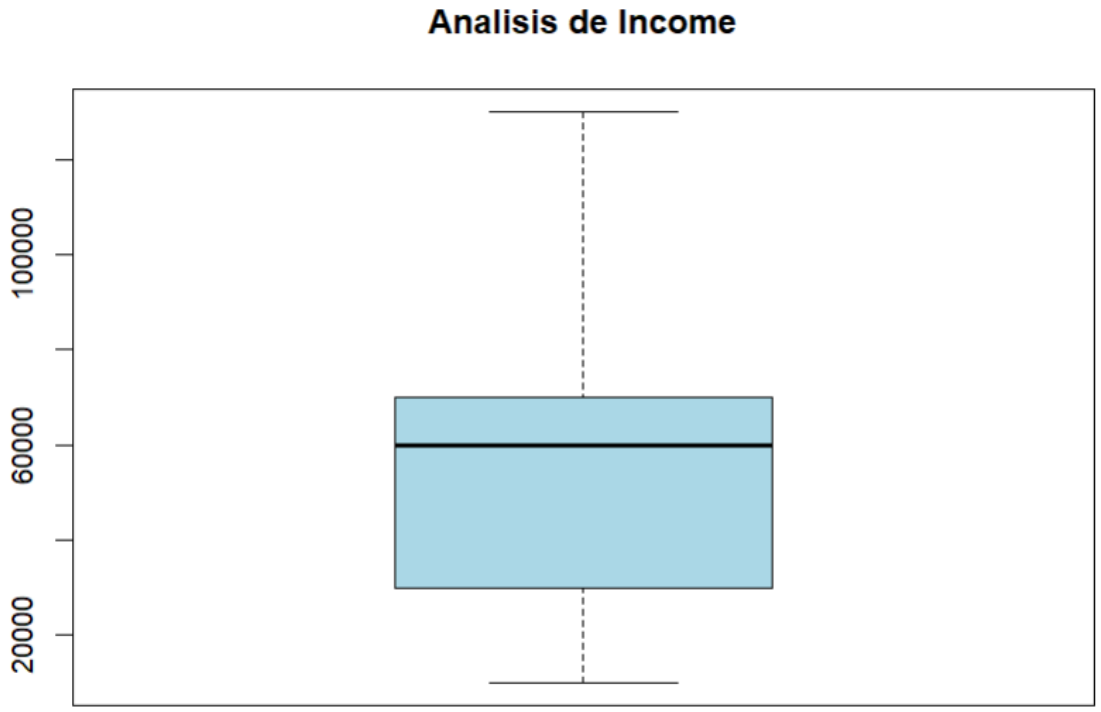

Pregunta: ¿Existen datos atípicos en los ingresos de los clientes? Si es así, ¿cómo propondrías suavizar estos valores para no afectar el análisis?

Sí existen valores atípicos en la variable Income, los cuales se observan en el boxplot como puntos fuera del rango intercuartílico.

Estos valores extremos pueden afectar el análisis estadístico al distorsionar medidas como la media y la varianza.

Para suavizarlos, se aplicó el método del rango intercuartílico (IQR), estableciendo un límite superior de 1.5 veces el IQR y reemplazando los valores que superan ese límite por el valor máximo permitido.

4. Análisis de la relación entre ingresos (Income) y compra de bicicletas (Purchased Bike): Utiliza un gráfico de boxplot para analizar la relación entre el ingreso de los clientes y la compra de bicicletas.

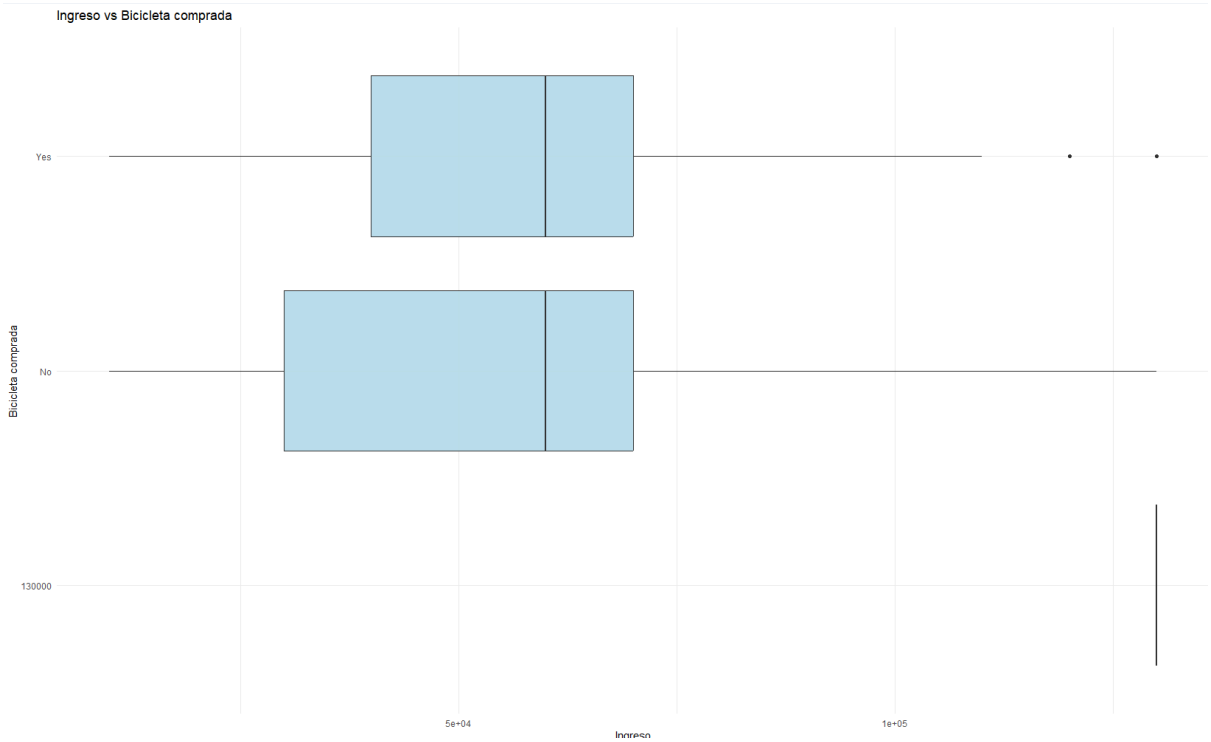

Pregunta: ¿Observas alguna tendencia o patrón que sugiera que los ingresos influyen en la decisión de comprar una bicicleta?

No se mira una tendencia clara de que los ingresos influyen en la compra de una bicicleta, ya que la mediana de ambos son muy similares y existe una amplia superposición entre ambos, aunque también se puede apreciar que el grupo que no compró la bicicleta presenta una mayor dispersión de sus ingresos y los que sí se encuentran concentrados, esto podría representar una pequeña tendencia a que los ingresos puedan influir en la compra, al no ser tan clara no se toma como evidencia conclusiva.

5. Distribución de la variable Age: Usa un histograma para visualizar la distribución de la variable Age.

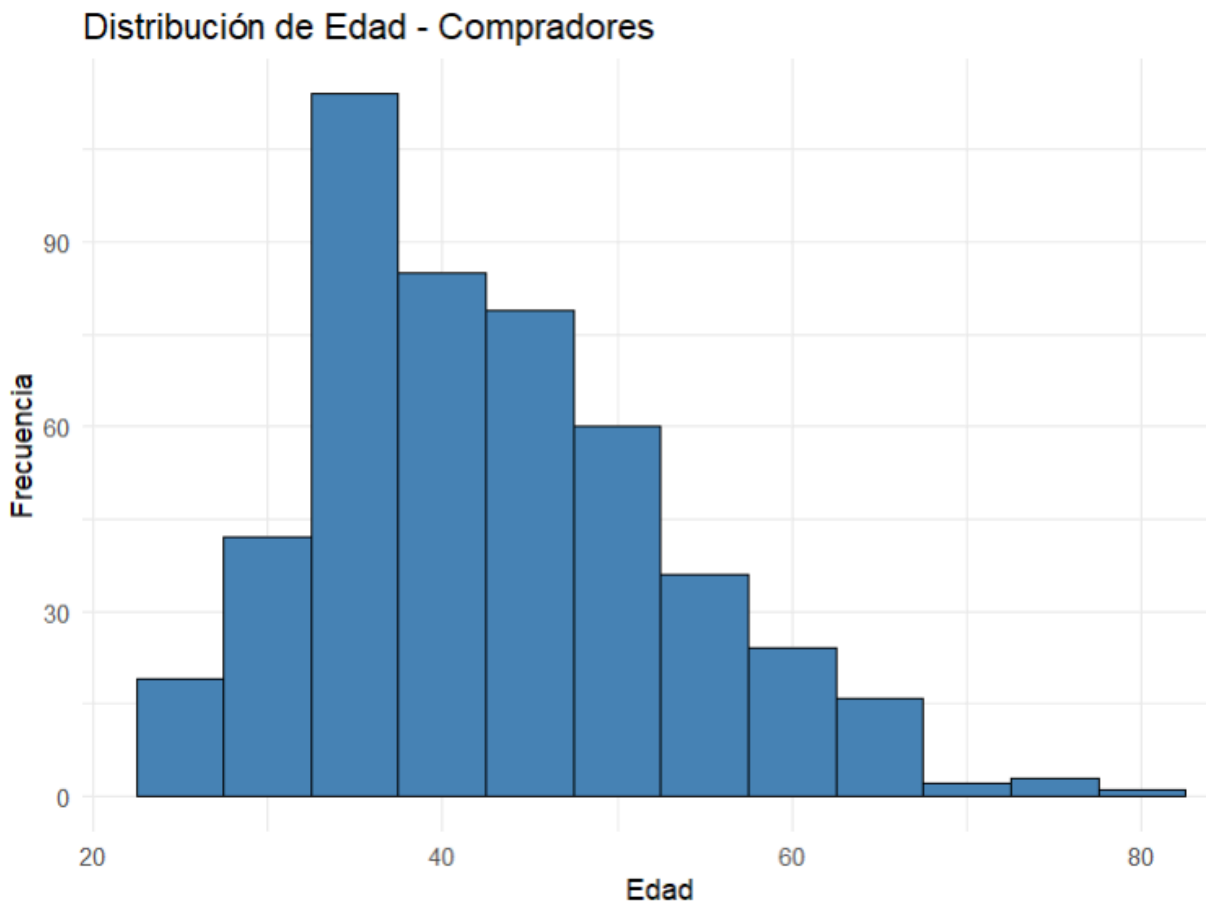

Pregunta: ¿Cómo está distribuida la edad de los compradores de bicicletas? ¿La mayoría de los compradores pertenecen a algún grupo de edad específico?

La distribución de la edad muestra que la mayoría de los compradores se concentran entre los 30 y 50 años. La frecuencia más alta se observa alrededor de los 35 a 45 años.

Esto indica que los compradores de bicicletas pertenecen principalmente al grupo de adultos jóvenes y de mediana edad. Hay menos compradores en edades muy bajas (20-25) y en edades mayores a 65 años.

6. Relación entre el número de autos (Cars) y la compra de bicicletas (Purchased Bike): Utiliza un gráfico de barras para visualizar la relación entre la cantidad de autos que posee un cliente y la decisión de comprar una bicicleta.

Pregunta: ¿Los clientes con más autos tienen una menor probabilidad de comprar una bicicleta?

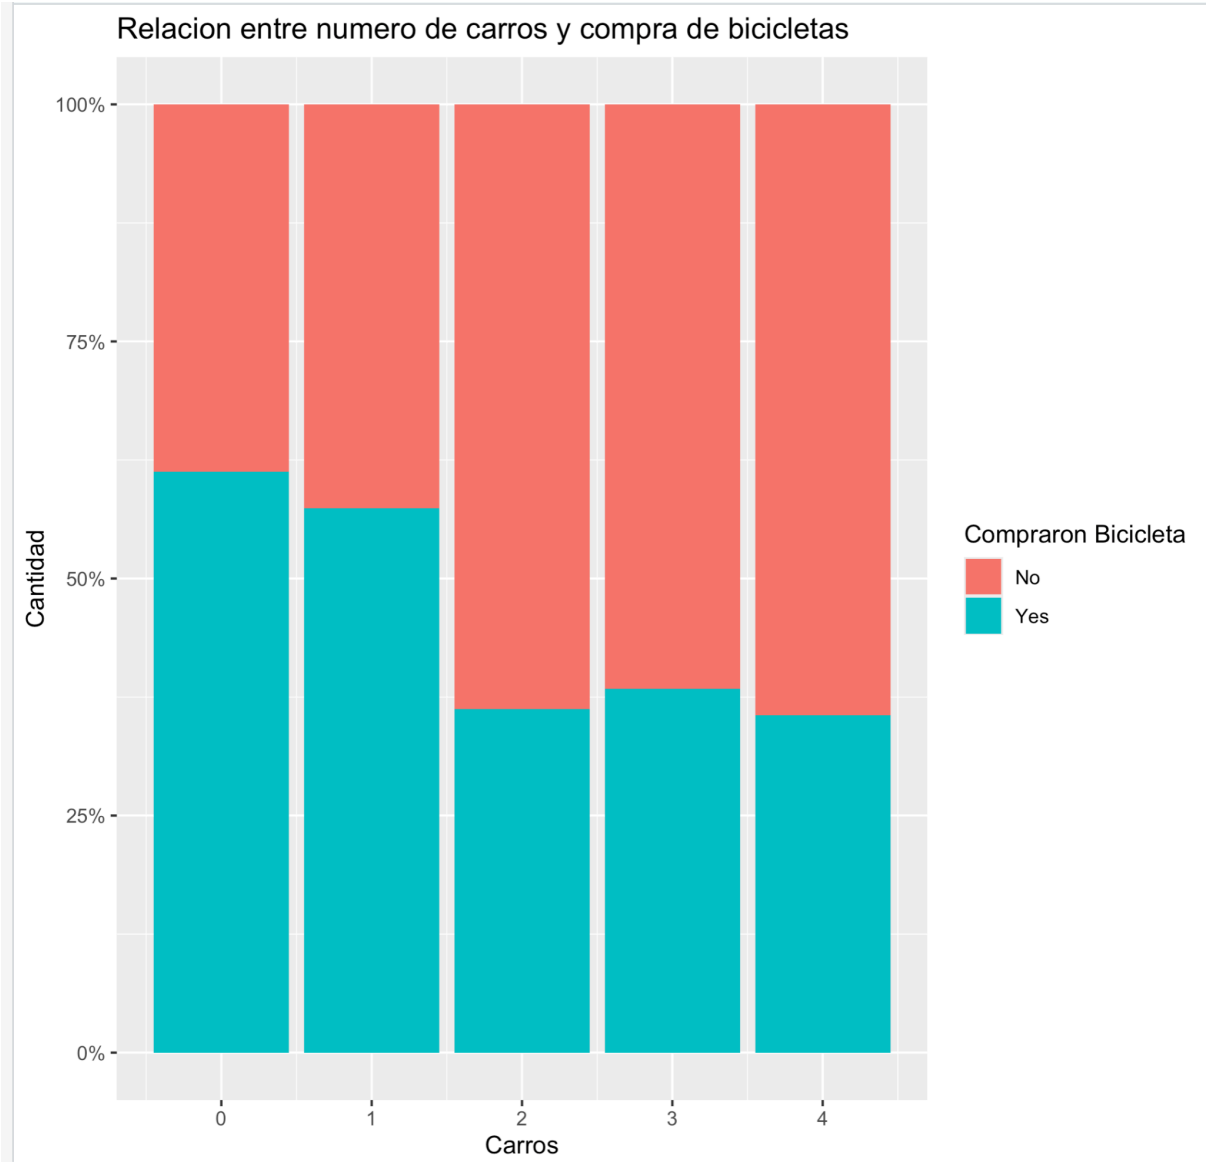

Sí, existe una relación inversa entre la cantidad de carros y la compra de bicicleta. Podemos observar que a partir de dos carros, la proporción de compradores se reduce, menos del 50% de los dueños se declinan por comprar una bicicleta si tienen dos o más vehículos.

7. Imputación de valores faltantes en las variables categóricas: Imputa los valores faltantes en las variables categóricas (como Gender) utilizando el método de moda u otros enfoques.

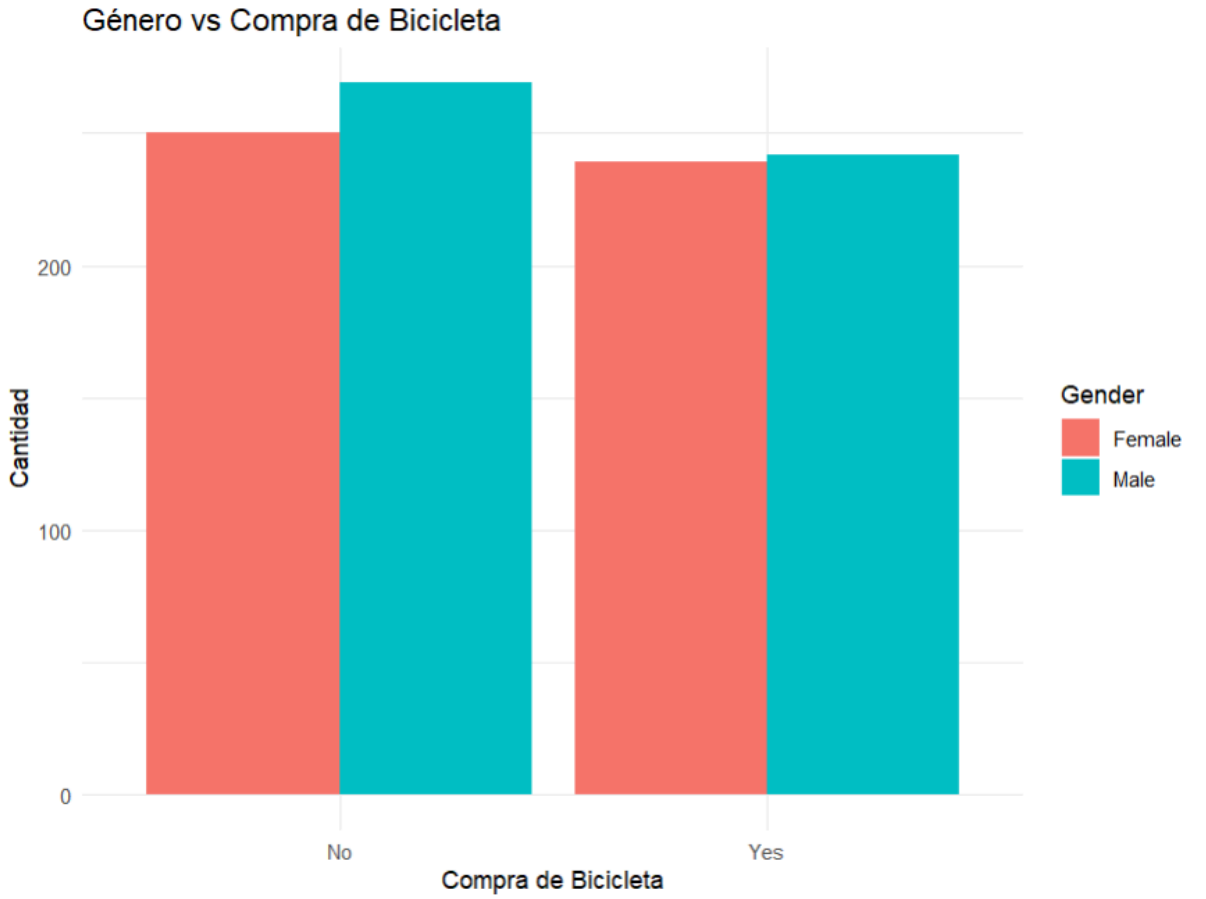

Pregunta: ¿Cómo afecta la imputación de valores en las variables categóricas al análisis de la compra de bicicletas?

En la gráfica se observa que hombres y mujeres tienen comportamientos muy parecidos en la compra de bicicletas. No hay una diferencia grande entre ambos grupos.

La imputación de los valores faltantes usando la moda no cambia de manera importante el resultado, ya que la cantidad de datos faltantes era baja.

Por lo tanto, el género no parece influir significativamente en la decisión de comprar una bicicleta.

8. Correlación entre variables numéricas clave (Age, Income, Cars): Genera una matriz de correlación entre las variables numéricas para explorar cómo se relacionan entre sí.

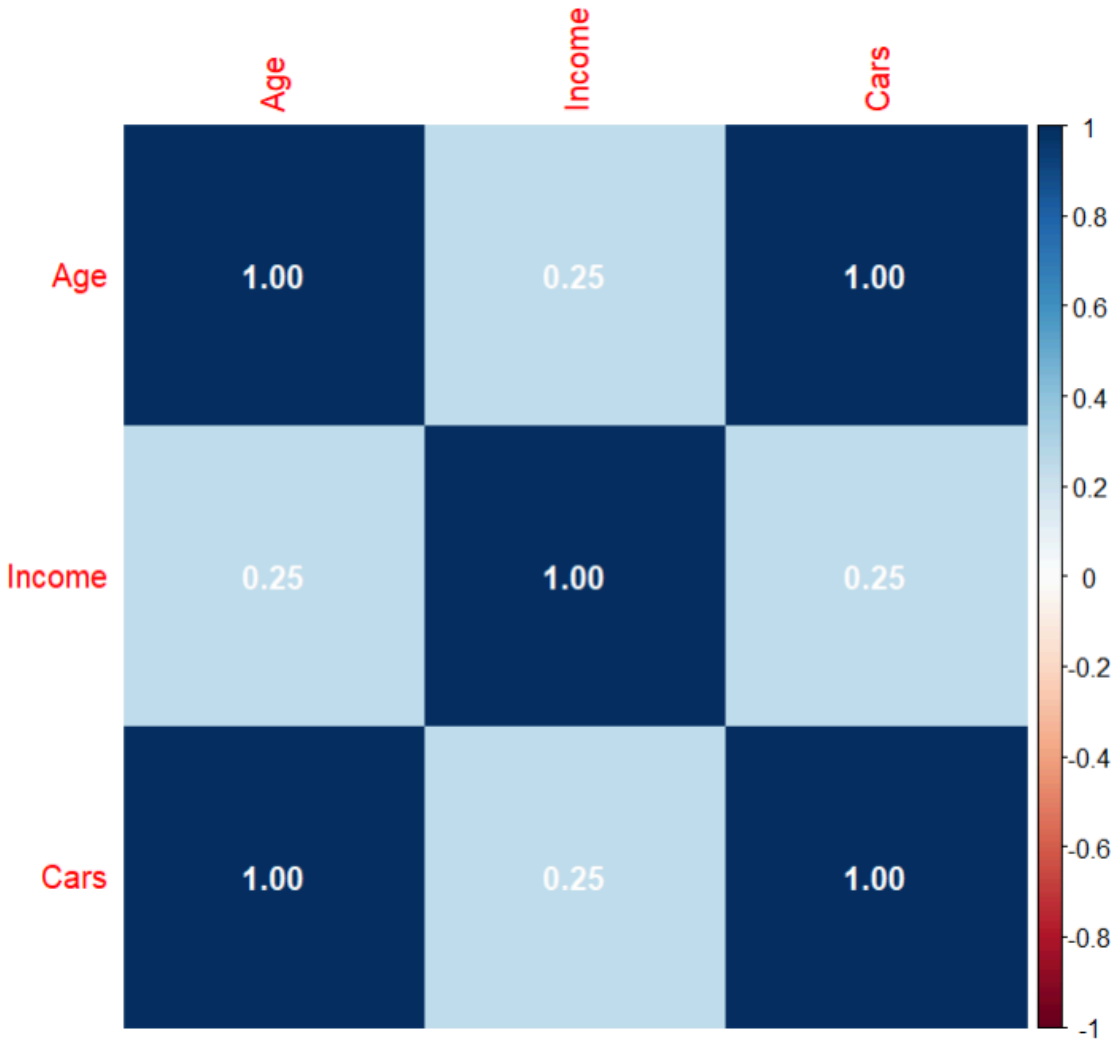

Pregunta: ¿Qué pares de variables numéricas muestran una correlación más fuerte y cómo podría esto influir en la probabilidad de comprar una bicicleta?

Las personas con mayor edad tienden a tener más autos, podría inferirse que quienes poseen más autos podrían tener menor necesidad de comprar bicicleta

9. Relación entre la distancia de viaje al trabajo (Commute Distance) y la compra de bicicletas: Crea un gráfico de barras que muestre la relación entre la distancia del trayecto al trabajo y la compra de bicicletas.

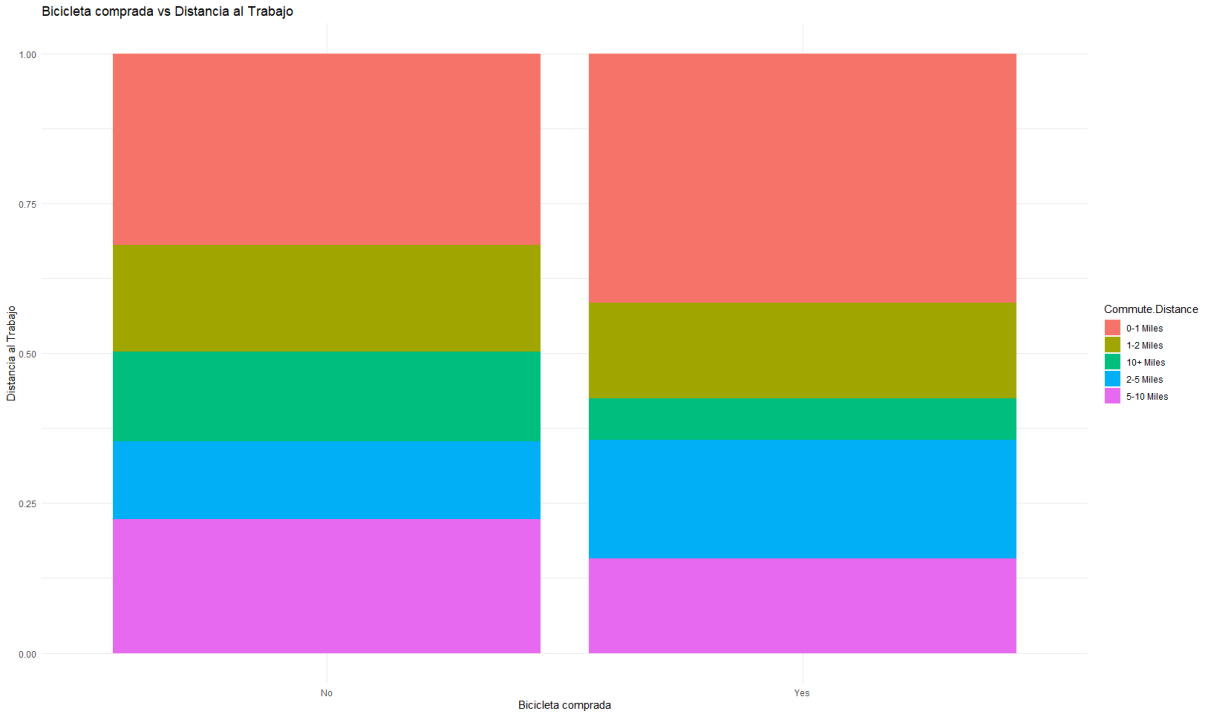

Pregunta: ¿Los clientes que viven más cerca del trabajo tienen una mayor probabilidad de comprar una bicicleta?

Si, se mira que en los compradores de bicicletas existe un mayor porcentaje en las personas que se encuentran entre 0-1 millas de su trabajo, esto se puede interpretar como que las personas que viven más cerca pueden usar la bicicleta como alternativa para viajar a su trabajo, aún así la diferencia no es extremadamente marcada, por lo que se podría realizar otros análisis estadísticos para poder confirmar esta relación.

10. Análisis de los valores atípicos en la variable Cars: Usa un boxplot para identificar posibles valores atípicos en la variable Cars.

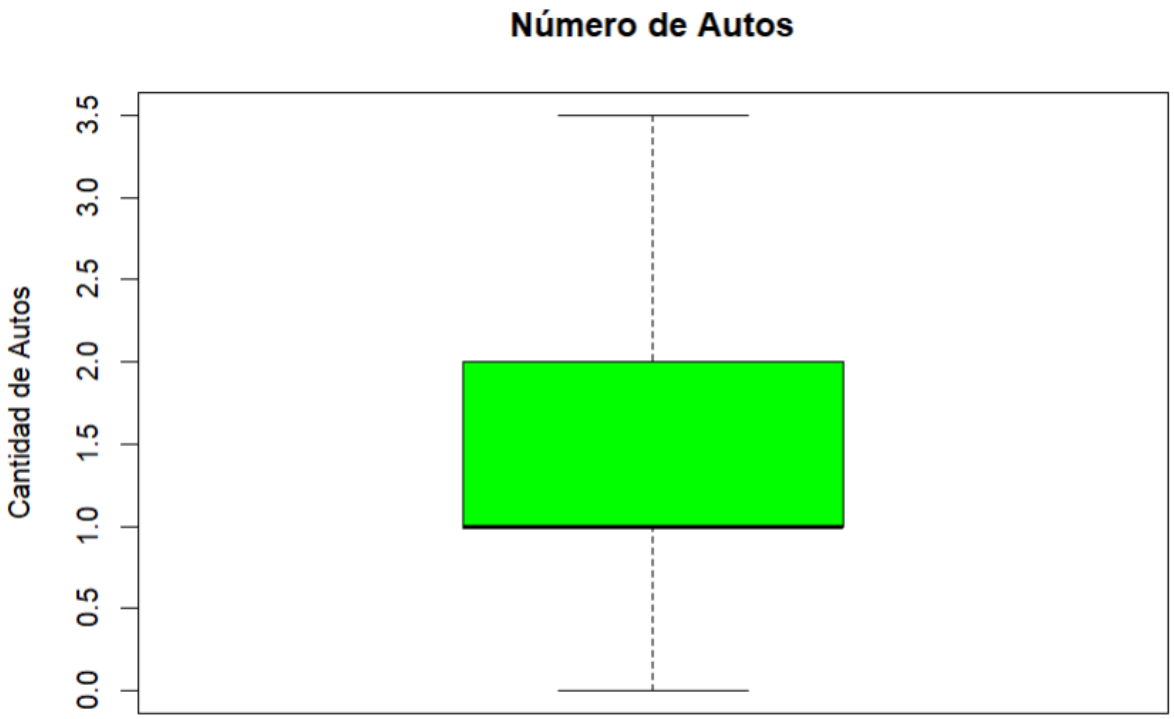

Pregunta: ¿Existen clientes con un número atípico de autos? ¿Cómo puedes suavizar estos valores para mejorar el análisis?

Al analizar el boxplot de la variable Cars, no se observan valores atípicos, ya que no aparecen puntos fuera de los rangos.

La distribución del número de autos se mantiene dentro de los límites normales, por lo que no es necesario aplicar ningún método de suavización.

11. Identificación de factores clave para la compra de bicicletas y estrategias de ventas Objetivo: Analizar qué variables tienen el mayor impacto en la decisión de compra y generar estrategias basadas en esos hallazgos.

Income: Se observa que los clientes con mayores ingresos tienden ligeramente a comprar más bicicletas.
Cars: El número de autos puede influir en la necesidad de adquirir una bicicleta.
Age: Ciertos rangos de edad muestran mayor concentración de compradores.
.

11.2 Generación de estrategias de ventas Basado en los insights obtenidos en la sección anterior, propone estrategias para aumentar las ventas de bicicletas.

- **Segmentación de clientes**
  - **¿Cuáles son los clientes más propensos a comprar bicicletas?**

    Los clientes más propensos a comprar bicicletas son personas entre 30 y 50 años, especialmente entre 35 y 45, con ingresos medios o medio-altos y con pocos autos (0–1 vehículos).

  - **¿Cómo podemos enfocar campañas publicitarias en esos clientes?**

    Para enfocar mejor las campañas, podemos dirigir la publicidad en redes sociales a personas de ciertas edades, con ingresos similares y que tengan interés en el deporte o en llevar un estilo de vida más saludable. También podemos ofrecer promociones pensadas específicamente para ese tipo de cliente, basándonos en lo que vimos en el análisis.

- **Promociones y descuentos personalizados**
  - **¿Se pueden crear ofertas dirigidas a clientes con ciertos niveles de ingreso o características demográficas?**

    Sí se pueden hacer ofertas pensadas según el tipo de cliente. Por ejemplo, a personas con ingresos medios se les puede dar la opción de pagar en cuotas o vender la bicicleta con accesorios incluidos en un combo. A los adultos jóvenes se les pueden ofrecer descuentos por tiempo limitado o beneficios por ser clientes frecuentes, de forma que las promociones se ajustan mejor a lo que cada grupo puede pagar y es más probable que compren.

- **Ubicación y accesibilidad**
  - **¿Podría ser una buena estrategia enfocarse en clientes que viven cerca del trabajo?**

    Sí, puede ser una buena estrategia enfocarse en clientes que viven cerca del trabajo, porque para ellos la bicicleta es una opción práctica y económica para transportarse. Si la distancia es corta, es más probable que consideren usar bicicleta en lugar de carro.

- **Campañas de concienciación y salud**

- **¿Cómo se puede incentivar la compra de bicicletas promoviendo beneficios de salud y medioambiente?**

  Se puede incentivar la compra resaltando que usar bicicleta mejora la salud, ayuda a reducir el estrés y también cuida el medioambiente al disminuir la contaminación. Mostrar estos beneficios de forma clara puede motivar a más personas a verla como una inversión en su bienestar.