Guatemala, 5 de marzo de 2026

CURSO: ESTADÍSTICA PARA DATA SCIENCE
CATEDRÁTICO: MSC. LUIS PEDRO FLORES
DOCUMENTO: LABORATORIO NO.6

NOMBRE: DIEGO JAVIER MORALES MONZÓN **CARNÉ:** 1132119
NOMBRE: ESTUARDO JOSÉ VILLEDA NAVARRO **CARNÉ:** 1003519
NOMBRE: JORGE WALDEMAR GARCÍA BALDIZÓN **CARNÉ:** 1220019
NOMBRE: JOSÉ DANIEL DE LEÓN CHANG **CARNÉ:** 1170419

INSTRUCCIONES: En este ejercicio, los estudiantes actuarán como analistas de datos para Joyas Exclusivas, una empresa que busca entender cómo diferentes características de los diamantes afectan su precio. El conjunto de datos contiene información sobre el peso en quilates (carat), el corte (cut), el color (color), la claridad (clarity), la profundidad (depth), el tamaño de la tabla (table), las dimensiones (x, y, z) y el precio (price). El objetivo es realizar un análisis exploratorio de las variables, limpieza de datos y ajustar un modelo de regresión lineal para predecir el precio de los diamantes en función de las otras características.

Análisis preliminar y limpieza de datos

1. Identificación de valores faltantes

```
> colSums(is.na(df))
  carat     cut   color clarity   depth   table   price       x       y       z
     67       0       0       0      99       0       0       0       0       0
>
```

2. Comienza con un análisis para identificar si hay valores faltantes en las variables.

```r
#Hago proceso de imputacion de variable faltantes
imputacion <- mice(df, m= 1, method = "pmm", maxit = 5)
df_limpio <- complete(imputacion)


#Valores atipicos
df_limpio$x <- suavizar(df_limpio$x)
df_limpio$y <- suavizar(df_limpio$y)
df_limpio$z <- suavizar(df_limpio$z)
boxplot(df_limpio$x, main="Boxplot dimensión X")
boxplot(df_limpio$y, main="Boxplot dimensión Y")
boxplot(df_limpio$z, main="Boxplot dimensión Z")
```

65:1 (Top Level)

Console Terminal Background Jobs

R 4.5.2 · C:/Users/jdele/OneDrive/Escritorio/Maestria/Estadistica para Data Science/Lab 6/

```
boxplot(df_limpio$y, main="Boxplot dimensión Y")
boxplot(df_limpio$z, main="Boxplot dimensión Z")
boxplot(df_limpio$x, main="Boxplot dimensión X")
#Hago proceso de imputacion de variable faltantes
imputacion <- mice(df, m= 1, method = "pmm", maxit = 5)

iter imp variable
 1   1  carat  depth
 2   1  carat  depth
 3   1  carat  depth
 4   1  carat  depth
 5   1  carat  depth
df_limpio <- complete(imputacion)
```

3. Pregunta: ¿Hay variables con valores faltantes? ¿Qué estrategias propondrías para manejarlos, como la imputación de valores o eliminación de filas incompletas?

La estrategía que utilizamos en esta ocasión sería imputar los valores faltantes, ya que representan menos del porciento de los datos.

carat tiene 67 valores faltantes y depth tiene 99 valores faltantes

```
#Hago proceso de imputacion de variable faltantes
imputacion <- mice(df, m= 1, method = "pmm", maxit = 5)
df_limpio <- complete(imputacion)
```

4. Detección de valores atípicos en las dimensiones (x, y, z): Realiza un análisis visual utilizando gráficos de caja y bigotes (boxplots) para identificar posibles valores atípicos en las dimensiones del diamante (x, y, z). Pregunta: ¿Existen valores atípicos significativos? ¿Qué sugerirías para suavizar o tratar estos datos atípicos?

Sí existen valores atípicos. Para suavizarlos vamos a utilizar el rango intercuartil con una combinación donde los valores atípicos menores al límite de 1.5*IQR, se sustituyen por el percentil 5 de los valores mientras que los valores atípicos mayores se sustituyen por el percentil 95.

```
suavizar <- function(x) {
 H <- 1.5 * IQR(x)
 qnt <- quantile(x, probs = c(0.25, 0.75))
 caps <- quantile(x, probs = c(0.05, 0.95))
 x[x < (qnt[1] - H)] <- caps[1]
 x[x > (qnt[2] + H)] <- caps[2]
 return(x)
}
```

x	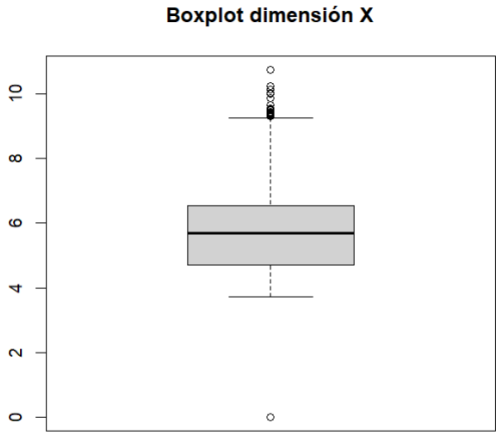 Boxplot dimensión X 0 2 4 6 8 10	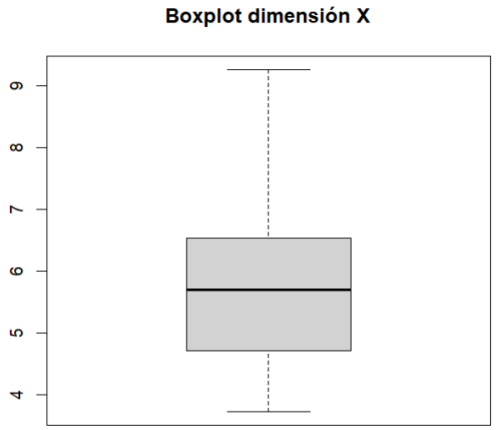 Boxplot dimensión X 4 5 6 7 8 9
y	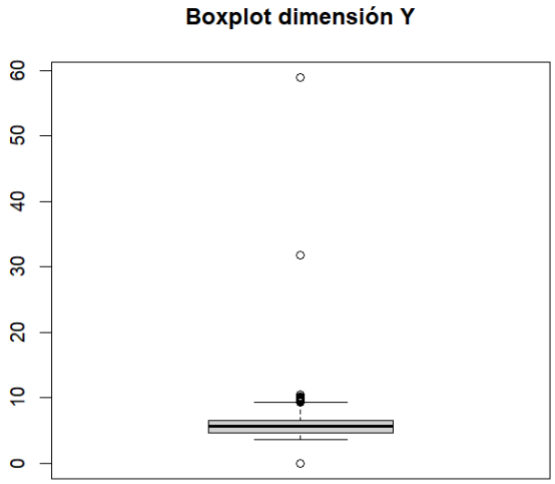 Boxplot dimensión Y 0 10 20 30 40 50 60	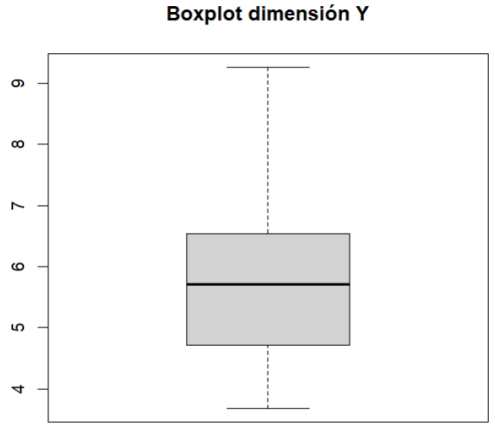 Boxplot dimensión Y 4 5 6 7 8 9
z	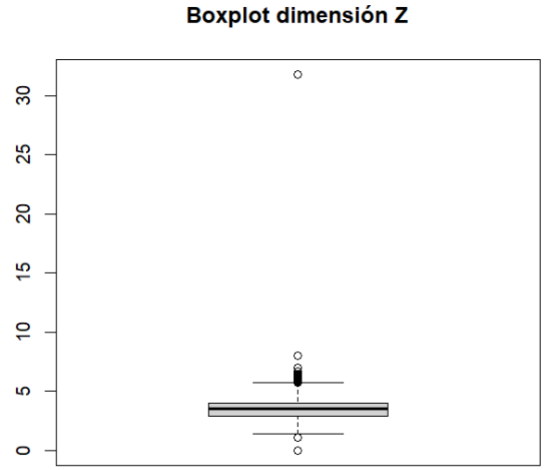 Boxplot dimensión Z 0 5 10 15 20 25 30	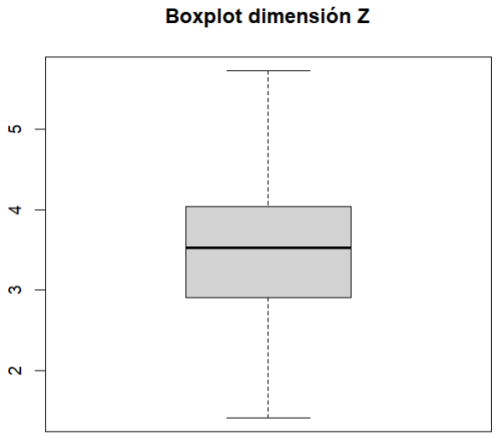 Boxplot dimensión Z 2 3 4 5

5. Distribución de las variables categóricas (cut, color, clarity): Utiliza gráficos de barras para visualizar la distribución de las variables categóricas relacionadas con el corte, color y claridad del diamante. Pregunta: ¿Cómo están distribuidas estas variables? ¿Hay algún grupo que prevalezca más?

Corte	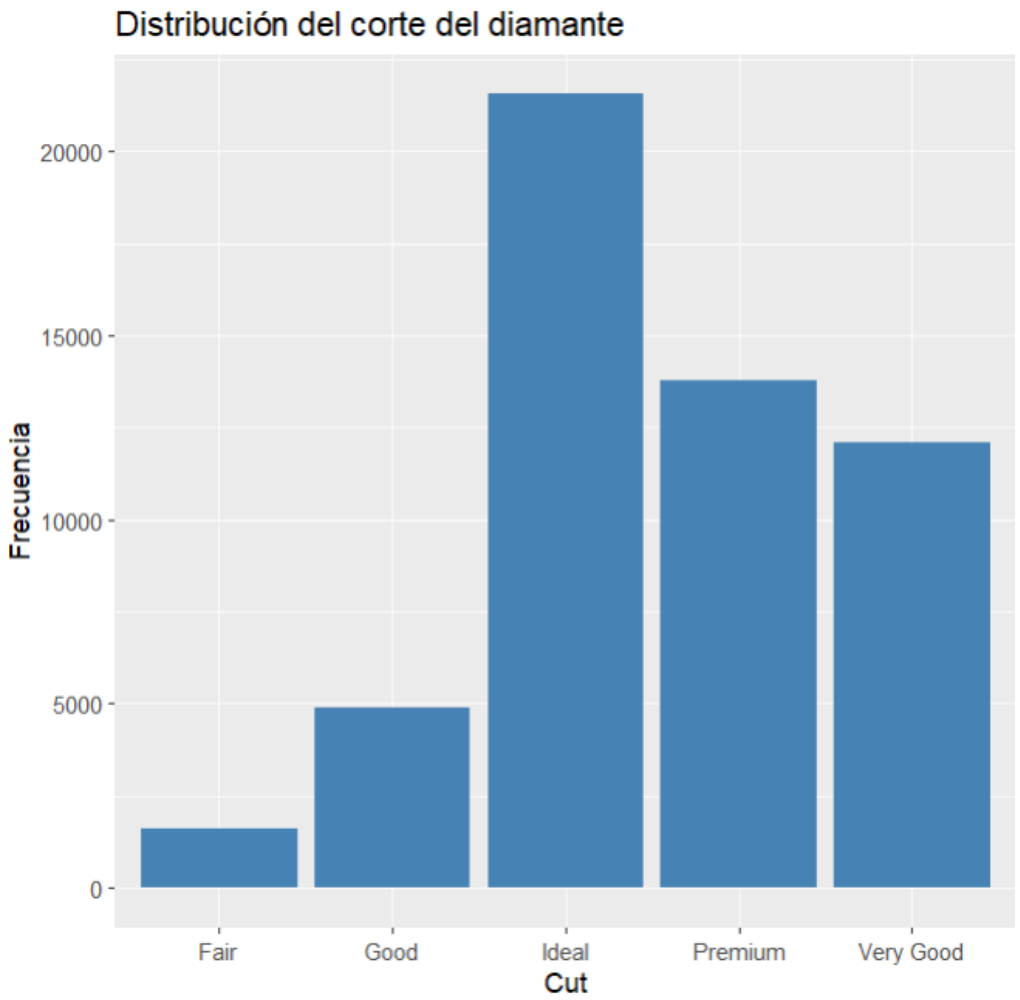

Color	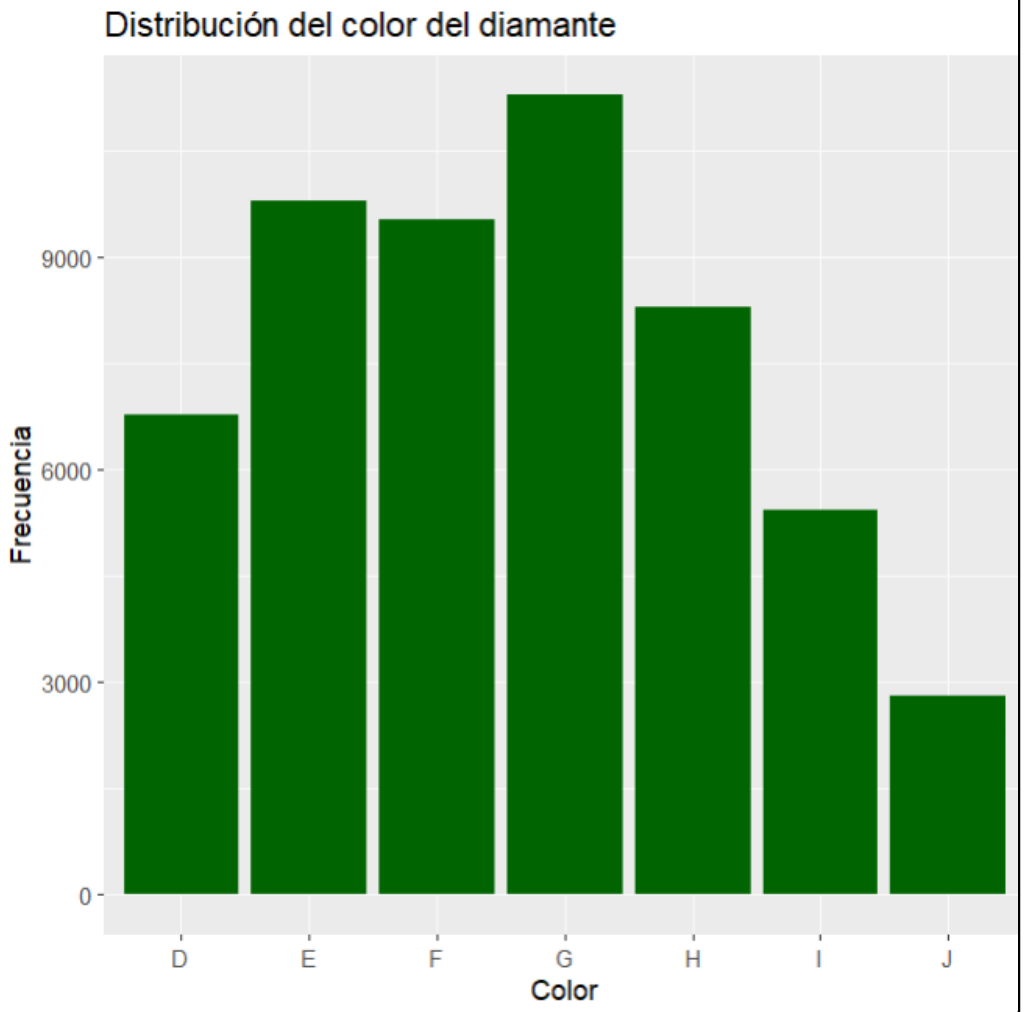
Claridad	

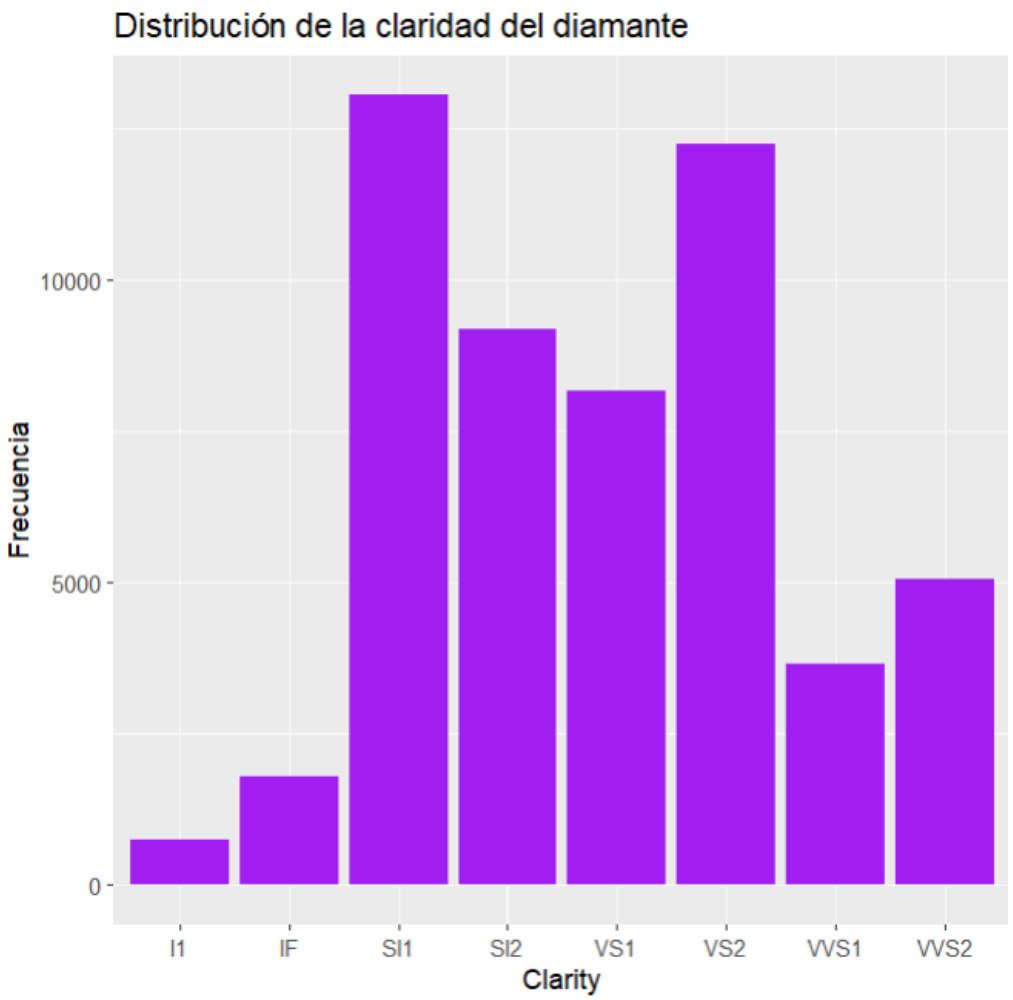

En la variable cut, se observa que el grupo Ideal es el más frecuente, seguido por Premium y Very Good, mientras que Fair es el menos común. Esto indica que la mayoría de los diamantes del dataset tienen cortes de buena o alta calidad.

Con la variable color, la gráfica muestra que la mayor frecuencia está en los colores G, E y F, mientras los colores I y J aparecen con menor frecuencia.

Con la variable clarity, la gráfica muestra que los niveles SI1 y VS2 presentan la mayor cantidad de diamantes, lo que sugiere que predominan niveles de claridad intermedios en el conjunto de datos.

6. Relación entre el peso en quilates (carat) y el precio (price): Usa un gráfico de dispersión para analizar la relación entre el peso en quilates y el precio de los diamantes. Pregunta: ¿Observas una relación directa entre el peso en quilates y el precio? ¿Existen valores atípicos que podrían distorsionar la relación?

Hay una relación entre el peso del diamante y su precio, si existen valores atípicos pero la tendencia muestra una alta relación.

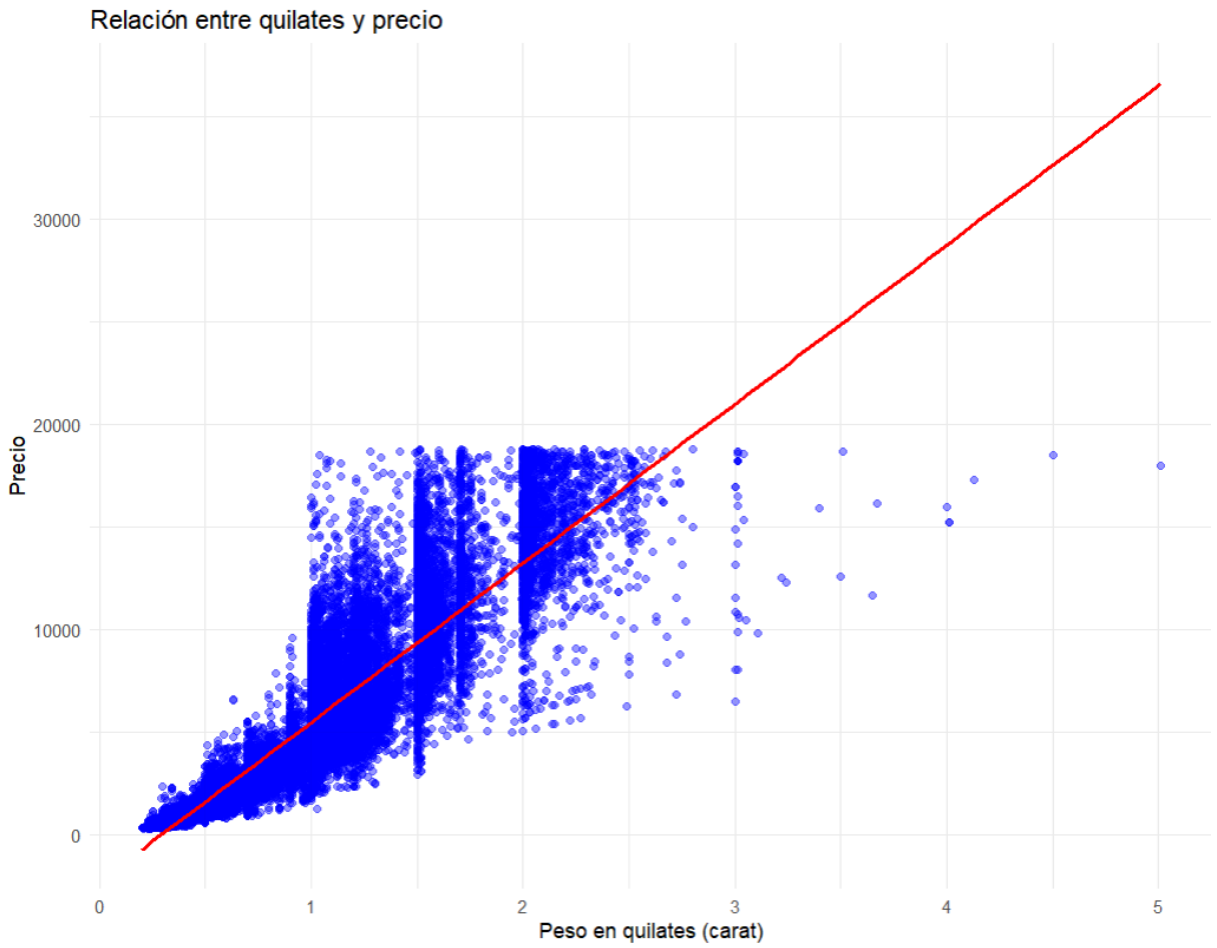

Análisis visual y exploratorio:

7. Correlación entre las variables numéricas: Genera una matriz de correlación para analizar las relaciones entre las variables numéricas (carat, depth, table, x, y, z) y el precio.

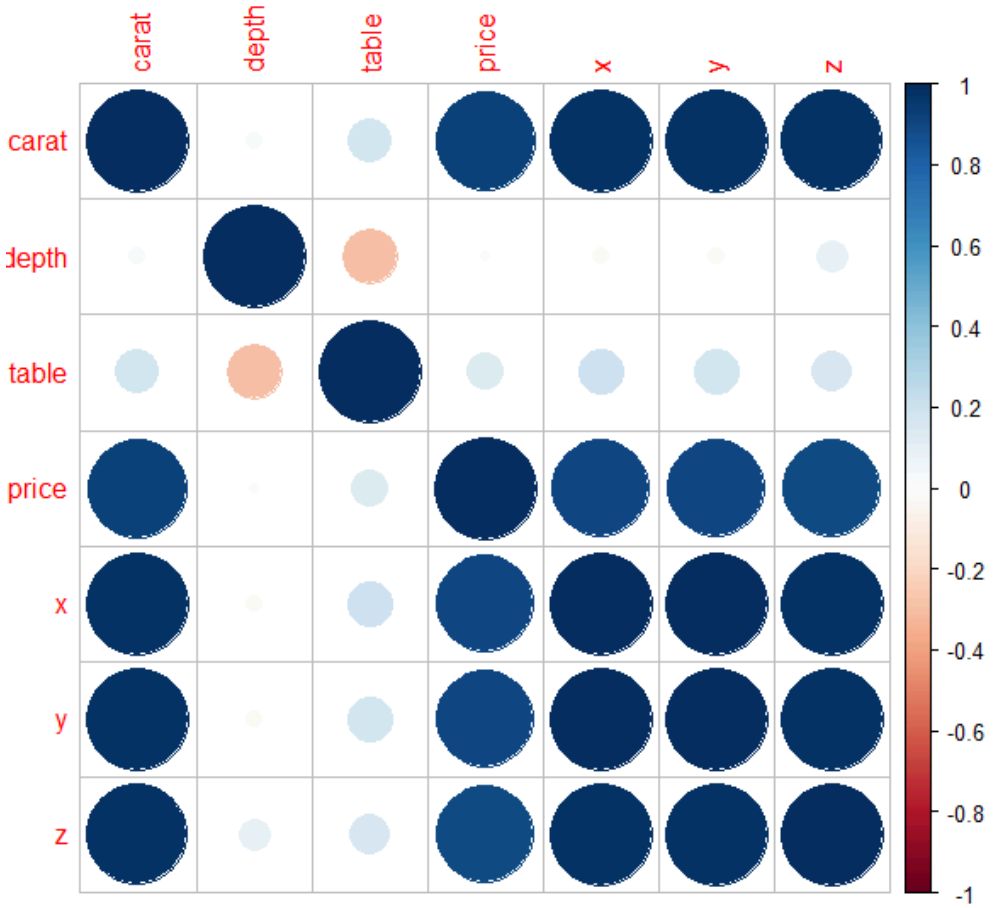

Pregunta: ¿Qué variables tienen una mayor correlación con el precio? ¿Hay alguna variable que sorprendentemente no esté correlacionada con el precio?

Las variables que tiene mayor correlación con el precio, son el peso, y las dimensiones, lo cual tiene sentido debido a que a mayor tamaño y peso el diamante debe ser más caro. La profundidad de un diamante (depth) curiosamente no muestra una correlación con el precio, aunque es un factor importante para el brillo del mismo no afecta al precio por el que se vende.

8. Distribución del precio (price): Crea un histograma para visualizar cómo está distribuido el precio de los diamantes. Pregunta: ¿La distribución del precio es simétrica o está sesgada? ¿Hay algún rango de precios en el que los diamantes son más comunes?

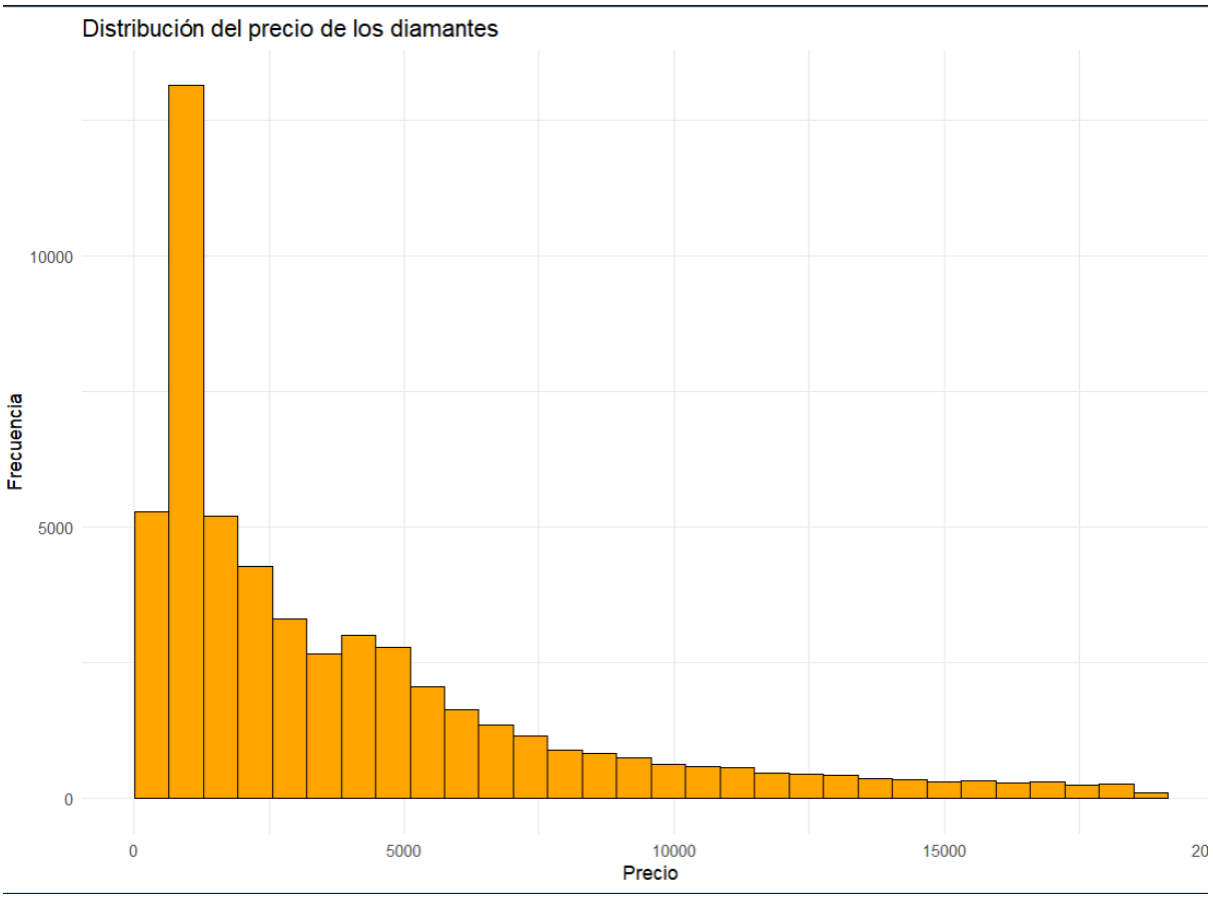

Sí, la gráfica está sesgada a la derecha positiva. El mercado tiene una mayor cantidad de diamantes accesibles y menos diamantes de alto valor.

Regresión lineal y análisis de los coeficientes:

9. Ajuste de un modelo de regresión lineal: Ajusta un modelo de regresión lineal utilizando las variables carat, cut, color, clarity, depth, table, x, y, z como predictoras del precio (price). Pregunta: ¿Qué variables tienen un coeficiente más alto y cómo impactan en el precio del diamante? Explica la magnitud y el signo de los coeficientes.

```
> summary(regresion_lineal)

Call:
lm(formula = price ~ carat + depth + table + color + x + cut +
    clarity, data = df_limpio)

Residuals:
     Min       1Q   Median       3Q      Max
-18416.6   -584.0   -153.3    389.8   6057.8

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -5335.478    340.987 -15.647  < 2e-16 ***
carat         7906.984     42.300 186.926  < 2e-16 ***
depth           -7.574      3.578  -2.117   0.0343 *
table          -16.762      2.546  -6.583 4.64e-11 ***
colorE        -200.913     15.649 -12.839  < 2e-16 ***
colorF        -265.806     15.825 -16.797  < 2e-16 ***
colorG        -442.199     15.495 -28.538  < 2e-16 ***
colorH        -872.894     16.473 -52.989  < 2e-16 ***
colorI       -1341.365     18.508 -72.477  < 2e-16 ***
colorJ       -2043.807     22.854 -89.431  < 2e-16 ***
x             101.050     17.959   5.627 1.85e-08 ***
cutGood       548.343     29.361  18.676  < 2e-16 ***
cutIdeal      787.244     29.209  26.952  < 2e-16 ***
cutPremium    723.878     28.186  25.682  < 2e-16 ***
cutVery Good  702.865     28.173  24.948  < 2e-16 ***
clarityIF    4809.186     44.606 107.816  < 2e-16 ***
claritySI1   3204.502     38.193  83.903  < 2e-16 ***
claritySI2   2315.367     38.352  60.371  < 2e-16 ***
clarityVS1   4072.381     38.971 104.496  < 2e-16 ***
clarityVS2   3779.870     38.371  98.508  < 2e-16 ***
clarityVVS1  4530.478     41.227 109.890  < 2e-16 ***
clarityVVS2  4489.819     40.099 111.968  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 988.4 on 53918 degrees of freedom
Multiple R-squared:  0.9261,	Adjusted R-squared:  0.9261
F-statistic: 3.217e+04 on 21 and 53918 DF,  p-value: < 2.2e-16
```

R^2 = 0.9261 → el modelo explica aproximadamente 92.61% de la variabilidad del precio.

La variable con el coeficiente más alto es carat (7906.984), lo que indica que el peso en quilates tiene el mayor impacto en el precio del diamante. El coeficiente positivo significa que por cada aumento de una unidad en carat, el precio del diamante aumenta aproximadamente en 7906.984 unidades.

Otras variables importantes son clarity y cut, donde categorías como clartityVVS2, clartityVVS1, y clartityVS1 tiene coeficientes positivos altos, lo que dice que los diamantes con mejor claridad tienden a tener precios elevados respecto a la categoría de referencia. Categorías del corte como Ideal, Premium y Very Good también presentan coeficientes positivos, dando entender que un mejor corte se asocia con u mayor precio.

10. Interpretación de los coeficientes del modelo: Analiza los coeficientes obtenidos del modelo de regresión lineal para entender cómo cada variable afecta el precio del diamante. Pregunta:

¿Cómo afecta un aumento de una unidad en carat, depth, o table al precio de un diamante? ¿Qué interpretaciones puedes hacer sobre las variables categóricas como cut, color, y clarity? Conclusión y estrategias:

Los coeficientes del modelo de regresión lineal permiten interpretar cómo cada variable afecta el precio del diamante, manteniendo las demás variables constantes.

El coeficiente del carat afecta positivamente al precio del diamante, aproximadamente por cada quilate que aumente el precio sube $7905.00, mientras que el depth y table afectan negativamente el precio, por cada unidad depth que aumenta disminuye $7.63 y por cada unidad de table que aumenta, disminuye $16.80.

En cuanto a las variables categóricas:

- **cut**: Las siguientes categorías: *Ideal, Premium y Very Good* indican que diamantes con mejor calidad de corte tienden a tener precios más altos en comparación con la categoría *Good*.
    - Ideal: $785
    - Premium: $722
    - Very Good: $701
    - Good: $546

- **color**: Los colores afectan negativamente el precio de un diamante
    - E: $200
    - F: $265
    - G: $442
    - H: $872
    - I: $1341
    - J: $2043

- **clarity**: Este coeficiente de claridad nos indica que entre mayor claridad tienen los diamantes los precios son más altos, ya que presentan menos imperfecciones.
    - IF: $4809
    - SI1: $3204
    - SI2: $2315
    - VS1: $4072
    - VS2: $3780
    - VVS1: $4530
    - VVS2: $4490

En general, el modelo muestra que **el peso del diamante, su claridad y su calidad de corte son factores clave que incrementan el precio de los diamantes**, mientras que el color afecta negativamente el precio.

11. Estrategia para precios basados en los resultados del modelo: Con base en los resultados obtenidos del modelo de regresión, plantea una estrategia para Joyas Exclusivas en cuanto a la valoración de los diamantes.

Pregunta: ¿Cómo deberían ajustar los precios de los diamantes según las características principales (como el peso en quilates y la claridad)? ¿Qué características son clave para la fijación de precios?

Con base a los resultados del modelo de la regresión lineal, tomando en cuenta únicamente las variables de carat, depth, table, x, cut, color y clarity cómo influyen en el precio de los diamantes.

El carat es el factor que más correlación tiene con respecto al precio, a medida que aumenta el tamaño del diamante su precio tiende a aumentar considerablemente. Claridad también impactan positivamente en el precio igual que el corte y el color