Guatemala, 12 de marzo de 2026

CURSO: ESTADÍSTICA PARA DATA SCIENCE
CATEDRÁTICO: MSC. LUIS PEDRO FLORES
DOCUMENTO: LABORATORIO NO.7

NOMBRE: DIEGO JAVIER MORALES MONZÓN **CARNÉ:** 1132119
NOMBRE: ESTUARDO JOSÉ VILLEDA NAVARRO **CARNÉ:** 1003519
NOMBRE: JORGE WALDEMAR GARCÍA BALDIZÓN **CARNÉ:** 1220019
NOMBRE: JOSÉ DANIEL DE LEÓN CHANG **CARNÉ:** 1170419

INSTRUCCIONES: En este ejercicio, los estudiantes asumirán el rol de analistas de datos para una compañía de seguros médicos. El objetivo es crear un modelo predictivo utilizando regresión lineal que estime los cargos médicos (charges) en función de las variables predictoras como la edad (age), el índice de masa corporal (bmi), el número de hijos (children), si el cliente es fumador (smoker), el sexo (sex), y la región (region). El modelo será evaluado utilizando un conjunto de datos de prueba y medido con métricas como RMSE y MAPE.

Análisis y preparación de datos

1. Exploración inicial de las variables.

```
>
> df_uso_completo <- rbind(df_uso_fumadores, df_uso_nofumadores)
> glimpse(df_entreno_crudo)
Rows: 1,265
Columns: 7
$ age      <int> 19, 18, 28, 33, 32, 31, 46, 37, 37, 60, 25, 62, 23, 56, 27, 19, 52, 23, 56, 30, 60, 30, 18, …
$ sex      <chr> "female", "male", "male", "male", "male", "female", "female", "female", "male", "female", "m…
$ bmi      <dbl> 27.900, 33.770, 33.000, 22.705, 28.880, 25.740, 33.440, 27.740, 29.830, 25.840, 26.220, 26.2…
$ children <int> 0, 1, 3, 0, 0, 0, 1, 3, 2, 0, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 1, 0, 1, 2, 3, 0, 2, 1, 2, 0,…
$ smoker   <chr> "yes", "no", "no", "no", "no", "no", "no", "no", "no", "no", "no", "yes", "no", "no", "yes",…
$ region   <chr> "southwest", "southeast", "southeast", "northwest", "northwest", "southeast", "southeast", "…
$ charges  <dbl> 16884.924, 1725.552, 4449.462, 21984.471, 3866.855, 3756.622, 8240.590, 7281.506, 6406.411, …
>
> summary(df_entreno_crudo)
      age            sex                bmi           children        smoker             region
 Min.   :18.00   Length:1265        Min.   :15.96   Min.   :0.000   Length:1265        Length:1265
 1st Qu.:27.00   Class :character   1st Qu.:26.22   1st Qu.:0.000   Class :character   Class :character
 Median :39.00   Mode  :character   Median :30.36   Median :1.000   Mode  :character   Mode  :character
 Mean   :39.26                      Mean   :30.63   Mean   :1.104
 3rd Qu.:51.00                      3rd Qu.:34.60   3rd Qu.:2.000
 Max.   :64.00                      Max.   :53.13   Max.   :5.000
    charges
 Min.   : 1122
 1st Qu.: 4720
 Median : 9386
 Mean   :13287
 3rd Qu.:16451
 Max.   :63770
>
```

```
> str(df_entreno_crudo)
'data.frame':   1265 obs. of  7 variables:
 $ age     : int  19 18 28 33 32 31 46 37 37 60 ...
 $ sex     : chr  "female" "male" "male" "male" ...
 $ bmi     : num  27.9 33.8 33 22.7 28.9 ...
 $ children: int  0 1 3 0 0 0 1 3 2 0 ...
 $ smoker  : chr  "yes" "no" "no" "no" ...
 $ region  : chr  "southwest" "southeast" "southeast" "northwest" ...
 $ charges : num  16885 1726 4449 21984 3867 ...
 - attr(*, "na.action")= 'omit' Named int [1:73] 60 80 104 126 149 150 151 152 153 154 ...
  ..- attr(*, "names")= chr [1:73] "60" "80" "104" "126" ...
>
```

El conjunto de datos contiene variables demográficas y de salud de los clientes de un seguro médico. Entre ellas se encuentran la edad, sexo, índice de masa corporal, número de hijos, si el cliente es fumador y la región donde vive. La variable objetivo del modelo es **charges**, que representa los costos médicos asociados a cada cliente.

Variable	**Tipo**	**Descripción**
age	numérica	Edad del cliente
sex	categórica	Sexo del cliente
bmi	numérica	Índice de masa corporal
children	numérica	Número de hijos
smoker	categórica	Si el cliente fuma
region	categórica	Región donde vive
charges	numérica	Costos médicos

2. Visualiza la distribución de las variables numéricas (age, bmi, charges).

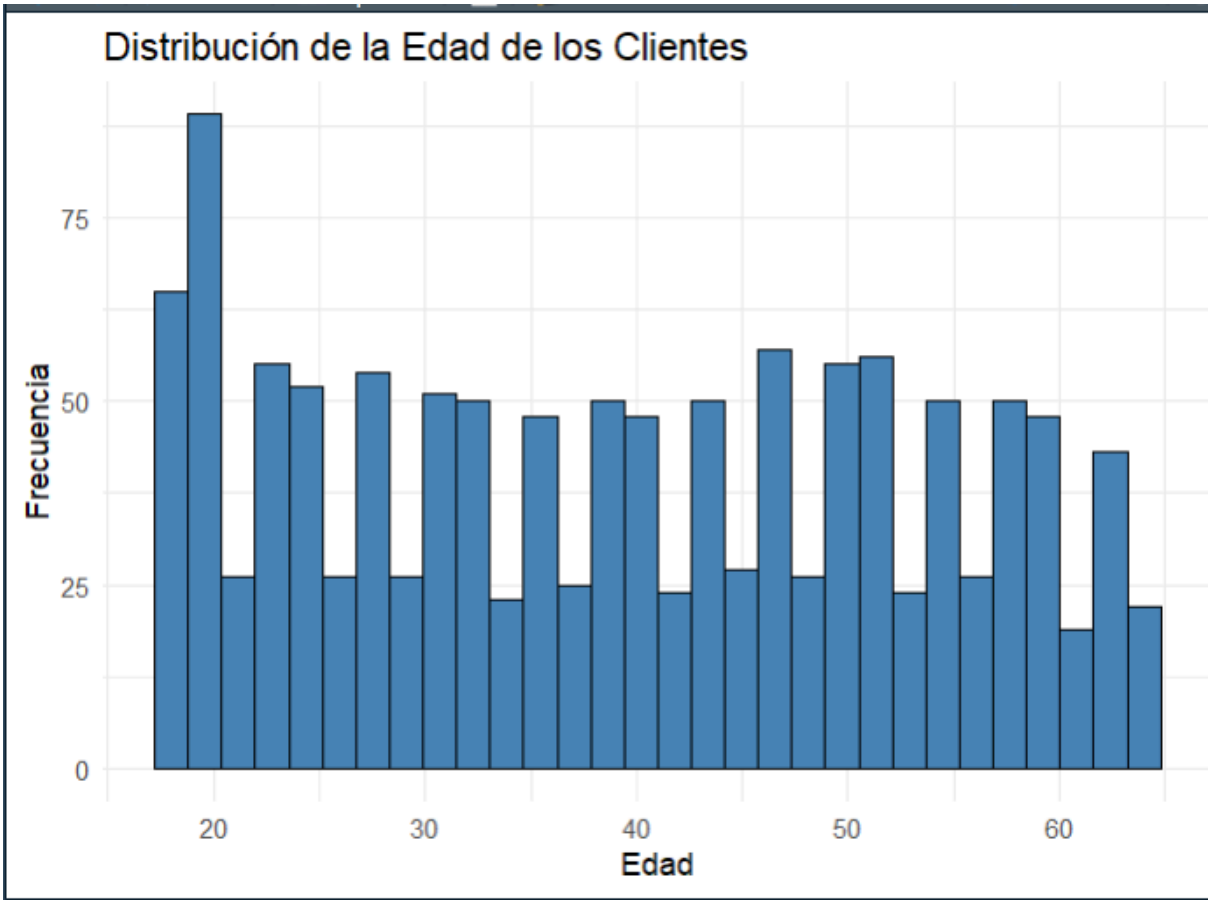

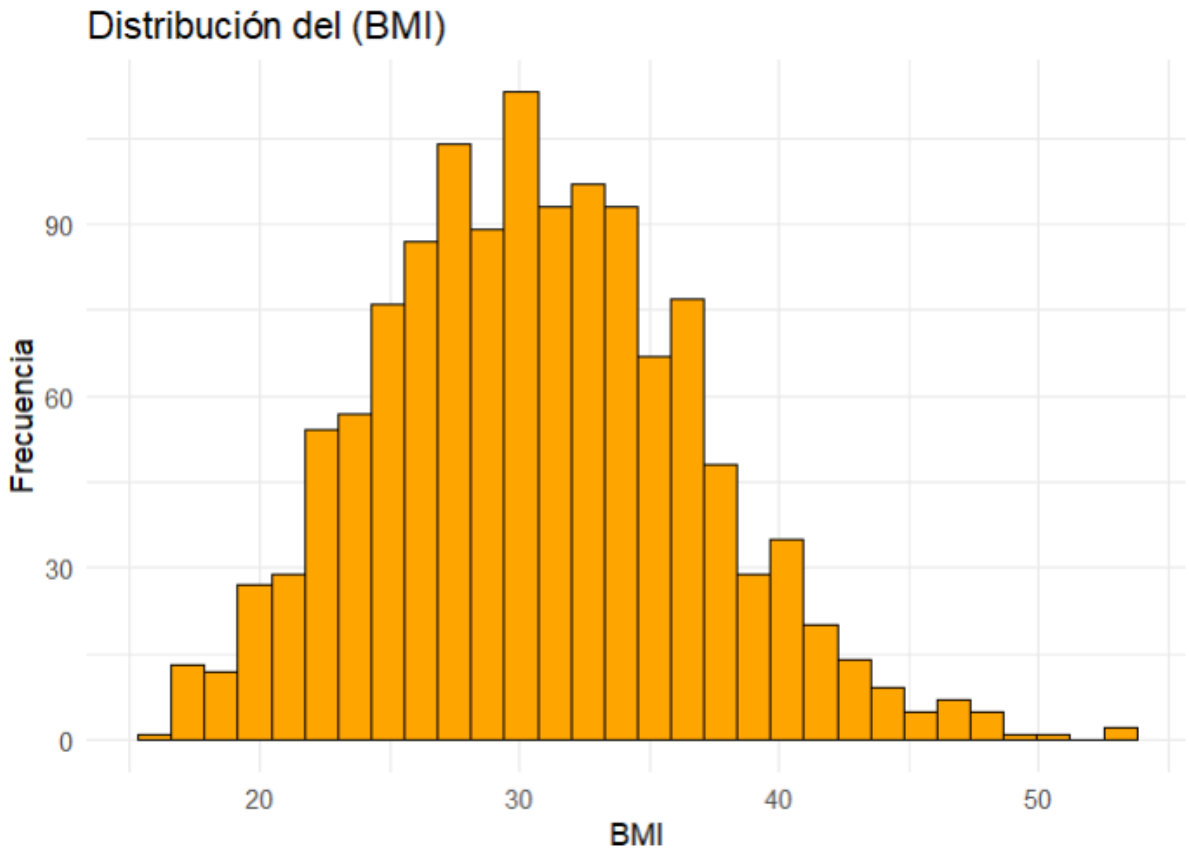
Distribución del (BMI)
Frecuencia
0
30
60
90
20
30
40
50
BMI

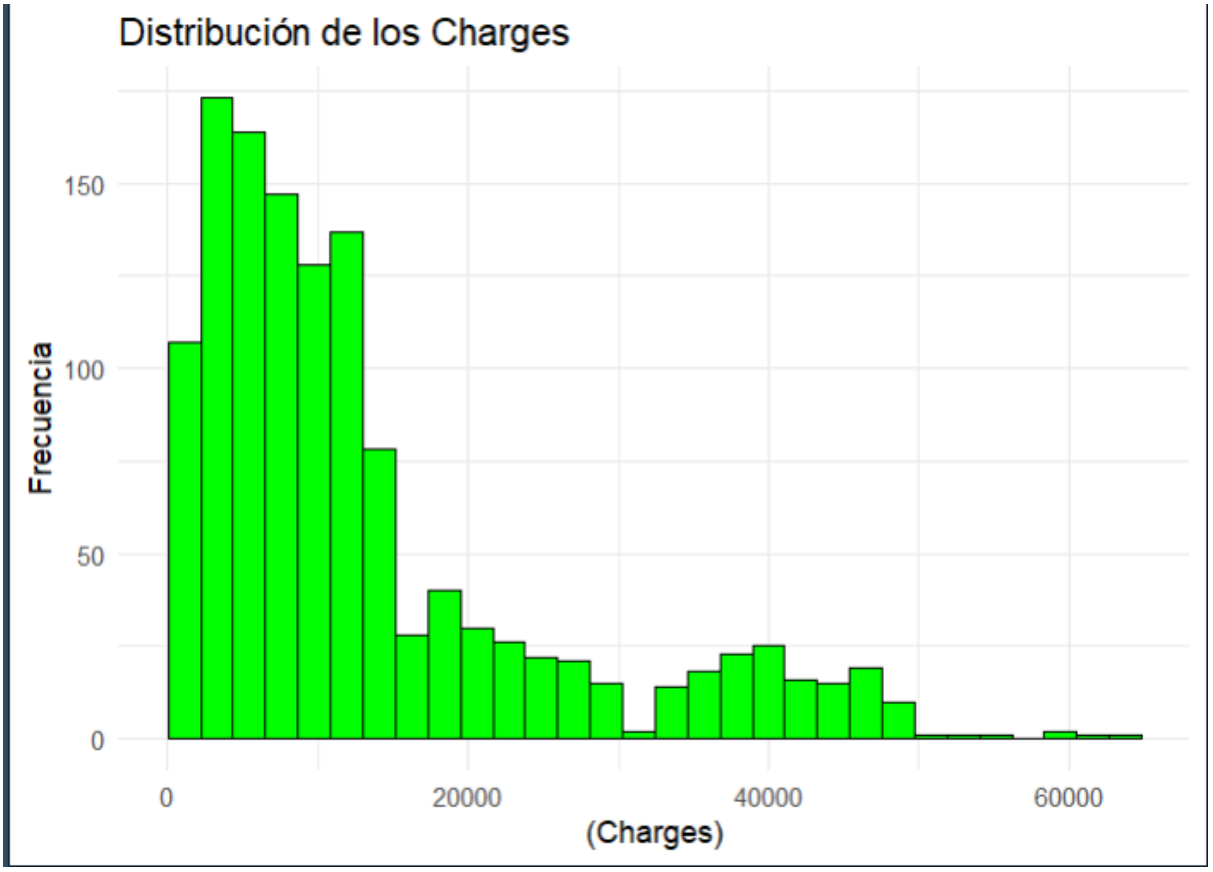
Distribución de los Charges
Frecuencia
0
50
100
150
0
20000
40000
60000
(Charges)

3. Pregunta: ¿Qué observas sobre la distribución de estas variables? ¿Hay sesgo en alguna de ellas?

La distribución de edad es bastante uniforme, no hay un pico central fuerte. No tiene un sesgo claro. Mientras que BMI tiene una distribución normal, tiene forma de campana y con un sesgo ligeramente hacia la derecha. Y charges si está sesgada, con un sesgo fuerte positivo.

4. Análisis de la variable charges: Usa un histograma para visualizar cómo están distribuidos los costos médicos (charges).

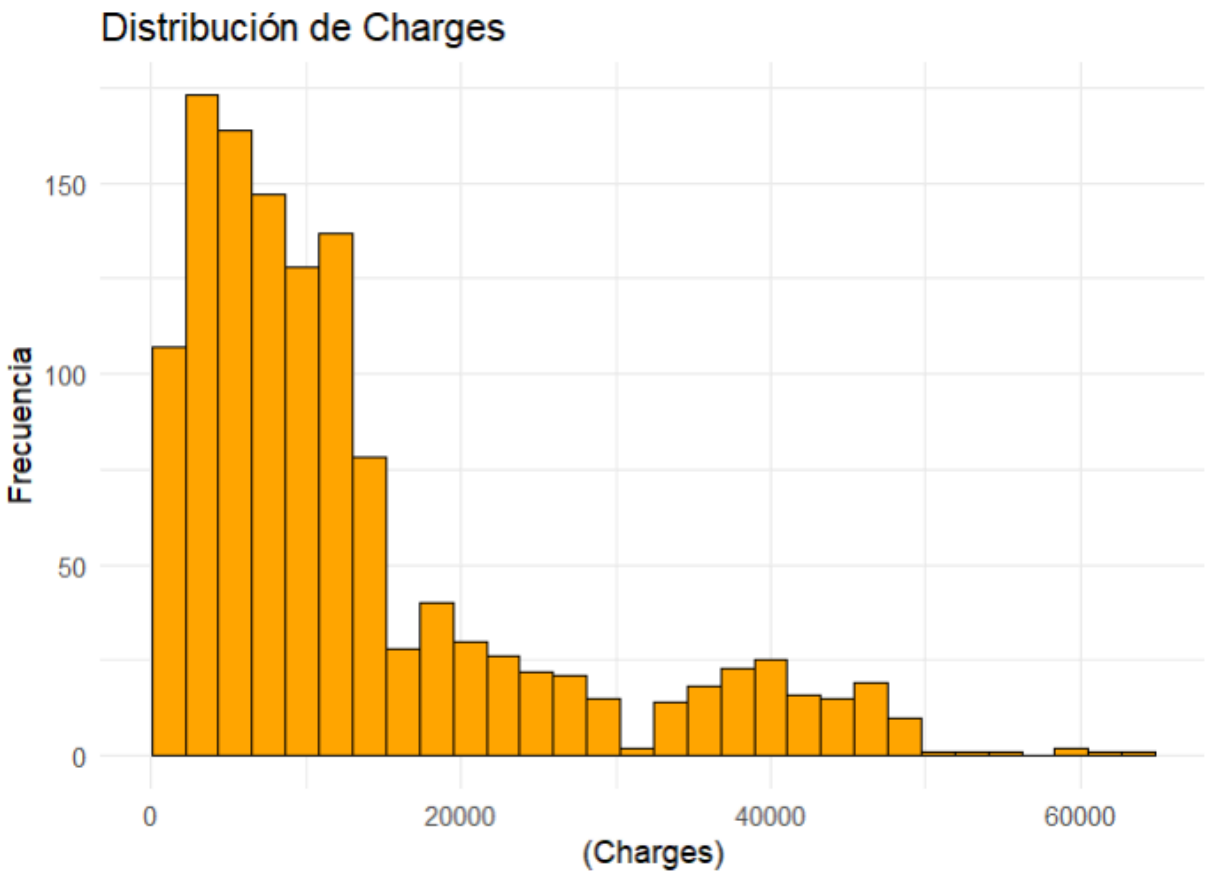

Pregunta: ¿La distribución de los cargos es simétrica o está sesgada? ¿Existen valores extremos que podrían afectar el análisis?

La distribución de la variable charges no es completamente simétrica. Se observa un sesgo hacia la derecha, lo que indica que la mayoría de los clientes tienen costos médicos relativamente bajos o moderados, mientras que un pequeño grupo presenta costos significativamente más altos.

Además, se pueden observar valores extremos (outliers) en la parte superior de la distribución, lo cual podría afectar el análisis y el ajuste del modelo, ya que estos valores aumentan la variabilidad de los datos.

5. Identificación de valores atípicos: Utiliza gráficos de caja y bigotes (boxplots) para identificar posibles valores atípicos en las variables numéricas como bmi, age, y charges.

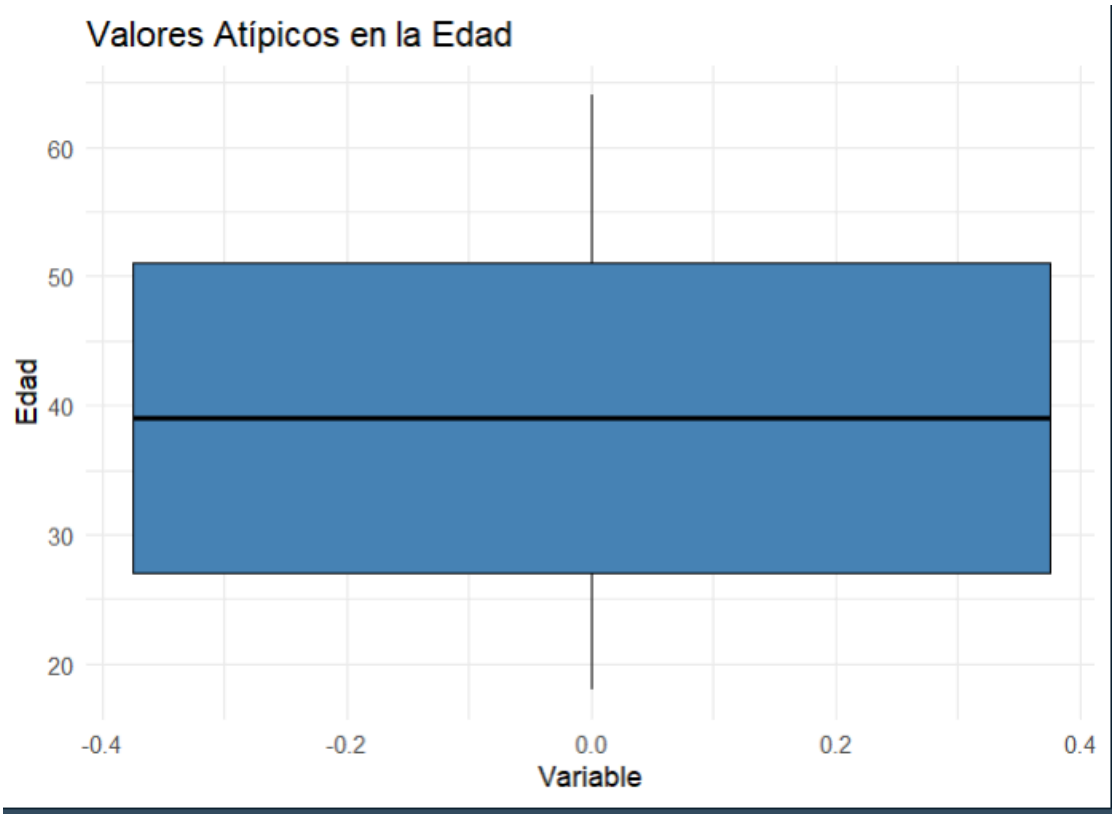

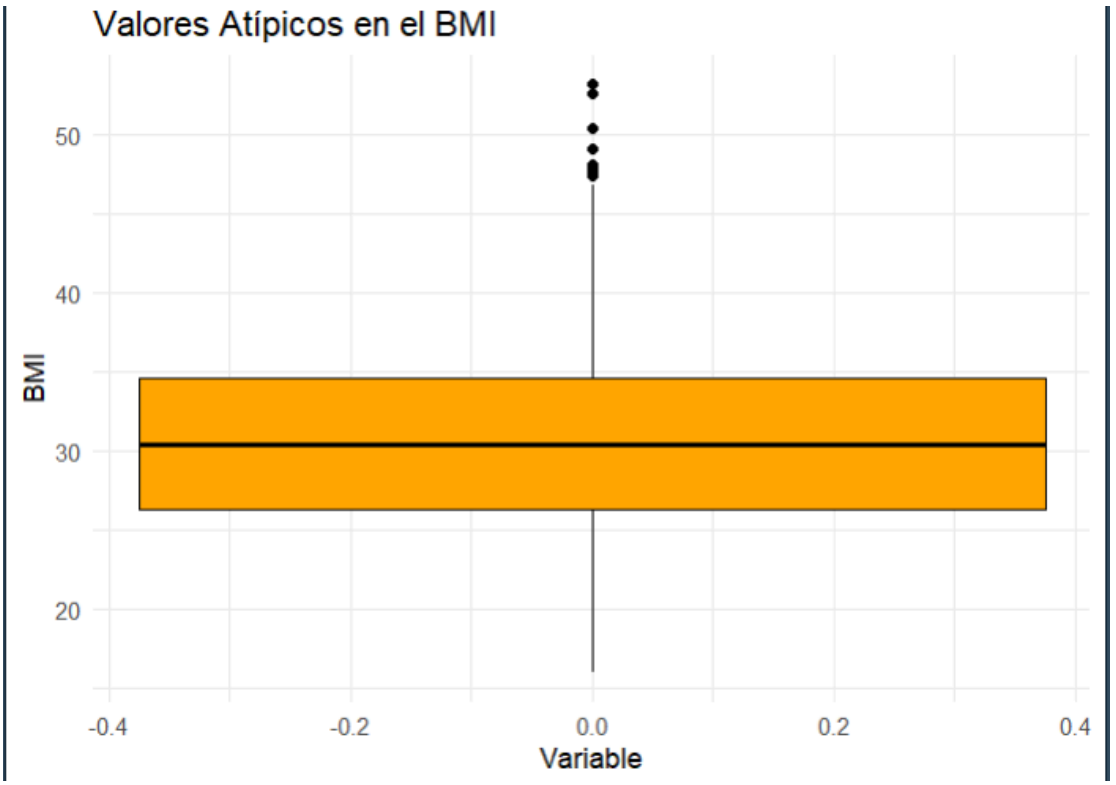

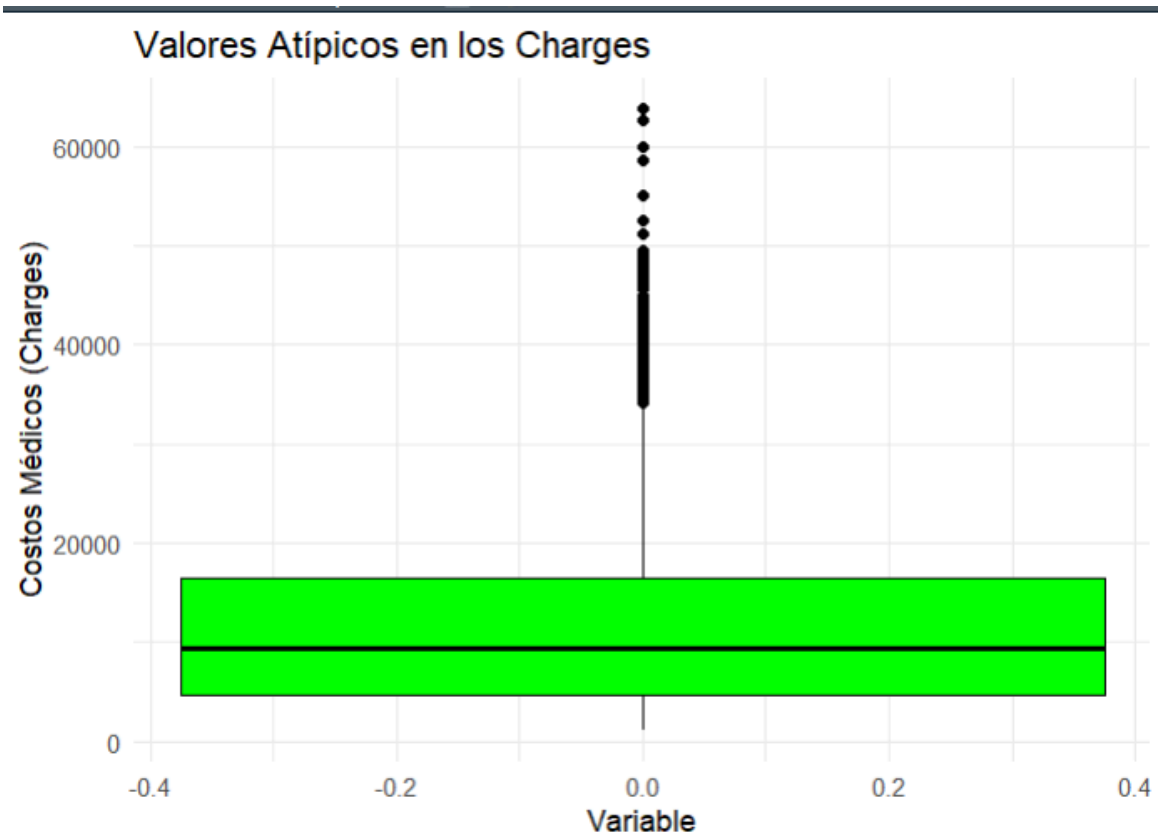

Pregunta: ¿Hay valores atípicos que deberían ser suavizados o eliminados antes de ajustar el modelo?

Los boxplot muestran que la variable age no presenta valores atípicos, ya que la mayoría de los datos están dentro de los límites. En bmi aparecen algunos valores atípicos altos, pero no son muchos y pueden ser valores reales, por lo que no necesariamente deben eliminarse. La variable charges si presenta valores atípicos, lo que indica que hay personas con costos médicos mayores que el resto. Los de charges deberían tratarse antes del modelado, pero preferiblemente mediante transformación o métodos robustos, no eliminándolos directamente.

7. División de los datos en entrenamiento y prueba (80%/20%): Divide el conjunto de datos en 80% para entrenamiento y 20% para evaluación utilizando una división aleatoria.

```r

split <- sample.split(df_entreno_crudo$smoker, SplitRatio = 0.8)

df_entreno <- subset(df_entreno_crudo, split == TRUE)
df_prueba <- subset(df_entreno_crudo, split == FALSE)
```

```
> #Ver tamaño de los conjuntos
> nrow(df_entreno)
[1] 1012
> nrow(df_prueba)
[1] 253
>
```

Pregunta: ¿Cómo se distribuyen las variables en los conjuntos de entrenamiento y prueba? ¿Hay algún desequilibrio que deba ser manejado?

El conjunto de datos fue dividido en 80% para entrenamiento y 20% para prueba utilizando una división aleatoria. El conjunto de entrenamiento se utiliza para ajustar el modelo de regresión lineal, mientras que el conjunto de prueba se utiliza para evaluar el desempeño del modelo en datos que no fueron utilizados durante el entrenamiento.

La distribución de los datos entre entrenamiento y prueba se mantiene equilibrada, permitiendo evaluar de forma adecuada la capacidad del modelo para generalizar a nuevos datos.

8. Ajuste de un modelo de regresión lineal: Ajusta un modelo de regresión lineal utilizando las variables age, sex, bmi, children, smoker, region para predecir los cargos médicos (charges).

```r
#ejercicio 8
#Modelo de regresión lineal para fumadores
modelo_lm_fumadores <- lm(charges ~ age + sex + bmi + children + region, data = entreno_fumadores)

#Modelo de regresión lineal para no fumadores
modelo_lm_nofumadores <- lm(charges ~ age + sex + bmi + children + region, data = entreno_nofumadores)
```

```
R 4.5.2 · C:/Users/jdele/OneDrive/Escritorio/Maestria/Estadistica para Data Science/Lab 7/

Call:
lm(formula = charges ~ age + sex + bmi + children + region, data = entreno_fumadores)

Residuals:
     Min       1Q   Median       3Q      Max 
-13803.2  -4482.6   -257.2   3503.7  30698.6 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -24040.69    2527.10  -9.513   <2e-16 ***
age                295.46      31.58   9.356   <2e-16 ***
sexmale           -439.12     877.59  -0.500    0.617    
bmi               1482.07      72.37  20.479   <2e-16 ***
children           274.32     376.55   0.729    0.467    
regionnorthwest   -418.08    1248.00  -0.335    0.738    
regionsoutheast  -1917.18    1178.66  -1.627    0.105    
regionsouthwest   -812.65    1275.29  -0.637    0.525    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6078 on 197 degrees of freedom
Multiple R-squared:  0.7466,	Adjusted R-squared:  0.7375 
F-statistic:  82.9 on 7 and 197 DF,  p-value: < 2.2e-16
```

```r
summary(modelo_lm_fumadores)
summary(modelo_lm_nofumadores)
```

173:1 (Top Level)

Console | Terminal | Background Jobs

```
R 4.5.2 · C:/Users/jdele/OneDrive/Escritorio/Maestria/Estadistica para Data Science/Lab 7/

Call:
lm(formula = charges ~ age + sex + bmi + children + region, data = entreno_nofumadores)

Residuals:
    Min      1Q  Median      3Q     Max 
-2636.0 -1863.2 -1384.2  -650.2 24872.3 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)     -2248.81     962.62  -2.336   0.0197 *  
age               262.21      11.62  22.563  < 2e-16 ***
sexmale          -224.44     326.18  -0.688   0.4916    
bmi                13.66      28.19   0.485   0.6280    
children          674.61     131.45   5.132  3.6e-07 ***
regionnorthwest  -455.35     465.53  -0.978   0.3283    
regionsoutheast -1075.88     481.73  -2.233   0.0258 *  
regionsouthwest -1134.09     469.36  -2.416   0.0159 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 4622 on 799 degrees of freedom
Multiple R-squared:  0.4126,	Adjusted R-squared:  0.4075 
F-statistic: 80.19 on 7 and 799 DF,  p-value: < 2.2e-16

>
```

Pregunta: ¿Qué variables tienen los coeficientes más altos y cómo impactan en los cargos médicos? ¿Qué interpretaciones puedes hacer sobre los coeficientes de las variables categóricas y numéricas? Evaluación del modelo:

Se ajustaron dos modelos de regresión lineal, uno para clientes fumadores y otro para no fumadores, utilizando como variables predictoras age, sex, bmi, children y region.

Los resultados muestran que variables como age y bmi tienen un impacto significativo en los cargos médicos. A medida que aumenta la edad o el índice de masa corporal, los costos médicos tienden a incrementarse.

Las variables categóricas como sex y region también influyen en el modelo, aunque generalmente con menor impacto que las variables numéricas.
Esto indica que factores relacionados con la edad y la condición física del cliente pueden tener una mayor influencia en los costos médicos estimados.

9. Evaluación utilizando RMSE (Raíz del Error Cuadrático Medio): Evalúa el modelo utilizando RMSE en el conjunto de prueba.

```
> #Calcular RMSE para fumadores
> RMSE(prueba_fumadores$pred, prueba_fumadores$charges)
[1] 4754.199
>
> #Calcular RMSE para no fumadores
> RMSE(prueba_nofumadores$pred, prueba_nofumadores$charges)
[1] 4561.939
```

Pregunta: ¿Cuál es el valor del RMSE y qué nos dice sobre el rendimiento del modelo en términos de la precisión de las predicciones?

El RMSE (Root Mean Squared Error) mide la diferencia promedio entre los valores reales de los cargos médicos y los valores predichos por el modelo.

Un valor de RMSE más bajo indica que las predicciones del modelo están más cerca de los valores reales. En este caso, el RMSE permite evaluar qué tan preciso es el modelo al estimar los costos médicos tanto para fumadores como para no fumadores.

Esto ayuda a determinar si el modelo tiene un buen desempeño al predecir los cargos médicos en el conjunto de datos de prueba.

10. Evaluación utilizando MAPE (Error Porcentual Absoluto Medio): Calcula el MAPE en el conjunto de prueba para evaluar el error porcentual promedio entre las predicciones y los valores reales.

```
> MAPE(prueba_fumadores$pred, prueba_fumadores$charges)
[1] 0.1426492
>
> #Calcular MAPE para no fumadores
> MAPE(prueba_nofumadores$pred, prueba_nofumadores$charges)
[1] 0.3025115
>
```

Pregunta: ¿El MAPE es bajo o alto? ¿Qué tanto están desviándose las predicciones en promedio con respecto a los valores reales? Conclusión y mejoras:

El MAPE (Mean Absolute Percentage Error) mide el error porcentual promedio entre los valores reales y las predicciones del modelo.

Este indicador permite interpretar el error del modelo en términos porcentuales. Un MAPE bajo indica que el modelo tiene buena precisión en sus predicciones, mientras que un MAPE alto indica que las predicciones se desvían considerablemente de los valores reales.

En este caso, el MAPE muestra qué porcentaje promedio se están desviando las predicciones del modelo respecto a los costos médicos reales, tanto para fumadores como para no fumadores.

Conclusiones

1. Las variables age, bmi y charges muestran diferentes distribuciones, donde charges presenta un sesgo hacia la derecha, indicando que algunos clientes tienen costos médicos mucho más altos que el resto.

2. Los boxplots permitieron identificar posibles valores atípicos, especialmente en la variable charges, lo que puede influir en el análisis y en el modelo.

3. Se utilizó un modelo de regresión lineal para predecir los costos médicos usando variables como edad, sexo, BMI, número de hijos y región.

4. Las métricas RMSE y MAPE permitieron evaluar el modelo, mostrando que las predicciones tienen un nivel de error razonable respecto a los valores reales.